



INVESTIGANDO PROBLEMAS DE ESCALABILIDADE DE E/S NO ALGORITMO SDDP EM AMBIENTES HPC

Marcelo Barros da Cruz

Dissertação de Mestrado apresentada ao Programa de Pós-graduação em Engenharia de Sistemas e Computação, COPPE, da Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Mestre em Engenharia de Sistemas e Computação.

Orientador: Nome do Orientador Sobrenome

Rio de Janeiro
Abril de 2026

INVESTIGANDO PROBLEMAS DE ESCALABILIDADE DE E/S NO
ALGORITMO SDDP EM AMBIENTES HPC

Marcelo Barros da Cruz

DISSERTAÇÃO SUBMETIDA AO CORPO DOCENTE DO INSTITUTO
ALBERTO LUIZ COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA DE
ENGENHARIA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO
GRAU DE MESTRE EM CIÊNCIAS EM ENGENHARIA DE SISTEMAS E
COMPUTAÇÃO.

Orientador: Nome do Orientador Sobrenome

Aprovada por: Prof. Nome do Primeiro Examinador Sobrenome
Prof. Nome do Segundo Examinador Sobrenome
Prof. Nome do Terceiro Examinador Sobrenome

RIO DE JANEIRO, RJ – BRASIL
ABRIL DE 2026

Barros da Cruz, Marcelo

Investigando Problemas de Escalabilidade de E/S no Algoritmo SDDP em Ambientes HPC/Marcelo Barros da Cruz. – Rio de Janeiro: UFRJ/COPPE, 2026.

XIII, 51 p.: il.; 29, 7cm.

Orientador: Nome do Orientador Sobrenome

Dissertação (mestrado) – UFRJ/COPPE/Programa de Engenharia de Sistemas e Computação, 2026.

Referências Bibliográficas: p. 49 – 51.

1. MPI-IO. 2. Lustre. 3. SDDP. 4. Computação de Alto Desempenho. 5. Escalabilidade de E/S. I. Sobrenome, Nome do Orientador. II. Universidade Federal do Rio de Janeiro, COPPE, Programa de Engenharia de Sistemas e Computação. III. Título.

*Dedico esta dissertação a [a
definir].*

Agradecimentos

ToDp: redigir agradecimentos finais. Coloque aqui seus agradecimentos.

Resumo da Dissertação apresentada à COPPE/UFRJ como parte dos requisitos necessários para a obtenção do grau de Mestre em Ciências (M.Sc.)

INVESTIGANDO PROBLEMAS DE ESCALABILIDADE DE E/S NO ALGORITMO SDDP EM AMBIENTES HPC

Marcelo Barros da Cruz

Abril/2026

Orientador: Nome do Orientador Sobrenome

Programa: Engenharia de Sistemas e Computação

A escalabilidade eficiente de E/S continua sendo um desafio crítico em aplicações paralelas de dados massivos, especialmente em sistemas de alto desempenho que lidam com grandes volumes de dados. Embora avanços como o uso de MPI-IO e sistemas de arquivos paralelos como o Lustre tenham contribuído significativamente, muitas aplicações ainda enfrentam gargalos que comprometem a performance. Esse problema é particularmente evidente em modelos de otimização utilizados no setor energético, como o SDDP, que demandam acesso frequente e distribuído a grandes conjuntos de dados. A eficiência da E/S torna-se, assim, um fator decisivo para a viabilidade e o desempenho de simulações complexas em ambientes paralelos. Esta dissertação investiga os gargalos de E/S da fase de simulação final do algoritmo SDDP e propõe uma arquitetura MPI-IO baseada em MPI-IO sobre Lustre, avaliada empiricamente nos ambientes AWS (FSx for Lustre) e Santos Dumont (LNCC).

Abstract of Dissertation presented to COPPE/UFRJ as a partial fulfillment of the requirements for the degree of Master of Science (M.Sc.)

INVESTIGATING I/O SCALABILITY ISSUES IN THE SDDP ALGORITHM ON HPC ENVIRONMENTS

Marcelo Barros da Cruz

April/2026

Advisor: Nome do Orientador Sobrenome

Department: Systems Engineering and Computer Science

Efficient I/O scalability remains a major challenge for parallel applications handling massive data volumes, particularly in high-performance computing environments. Although advances such as MPI-IO and parallel file systems like Lustre have significantly improved performance, many applications still face I/O bottlenecks that hinder scalability. This issue is particularly critical in energy sector optimization models, such as Stochastic Dual Dynamic Programming (SDDP), which require frequent and distributed access to large datasets. Therefore, optimizing I/O operations becomes essential to ensure the feasibility and efficiency of complex simulations in parallel computing systems. This dissertation investigates the I/O bottlenecks of the final simulation phase of the SDDP algorithm and proposes an MPI-IO-based architecture over Lustre, empirically evaluated on AWS (FSx for Lustre) and on the Santos Dumont supercomputer (LNCC).

Sumário

Lista de Figuras	x
Lista de Tabelas	xii
Lista de Abreviaturas	xiii
1 Introdução	1
2 Fundamentação Teórica	3
2.1 MPI, protocolos de comunicação e operações paralelas de arquivos . .	3
2.2 Sistema de arquivos paralelo Lustre	7
2.3 Adaptadores de rede em HPC: Ethernet e InfiniBand	7
2.4 Computação em nuvem para HPC: AWS	8
2.5 O Programa Mensal da Operação (PMO)	8
2.6 Algoritmo SDDP	9
2.6.1 Comparação dos formatos dos resultados	10
2.6.2 Arquitetura atual de E/S do SDDP	11
3 Paralelização dos Mecanismos de E/S do SDDP	13
3.1 Visão geral da arquitetura	13
3.2 Modelo de execução	14
3.3 Detalhes de implementação	15
3.3.1 Formato dos resultados	16
3.3.2 Implementação das escritas independentes	17
3.4 Considerações de configuração	19
3.5 Instrumentação	19
3.5.1 Registros gerados pela instrumentação	20
3.5.2 Tempo de computação	21
3.5.3 Tempo de coordenação MPI	21
3.5.4 Tempo total de E/S	21
3.5.5 Tempo de bloqueio na transferência dos blocos de dados . . .	22
3.5.6 Banda agregada média percebida pela aplicação	22

4	Avaliações	25
4.1	Experimento AWS	26
4.1.1	Avaliação da implementação atual	27
4.1.2	Avaliação da implementação MPI-IO com escritas independentes	28
4.1.3	Análise comparativa	29
4.1.4	Avaliação do impacto do número de OSTs	34
4.2	Experimento SDumont	37
4.2.1	Avaliação da implementação atual	38
4.2.2	Avaliação da implementação MPI-IO com escritas independentes	39
4.2.3	Análise comparativa	39
4.3	Síntese das avaliações	45
5	Trabalhos relacionados	47
6	Conclusões e trabalhos futuros	48
	Referências Bibliográficas	49

Lista de Figuras

2.1	Relação entre comunicação ponto a ponto e E/S paralela. No modelo centralizado, os resultados passam por um processo escritor; no modelo MPI-IO, os próprios processos escrevem diretamente no arquivo.	4
2.2	Diferença entre escritas independentes e coletivas em MPI-IO. Escritas independentes preservam autonomia dos processos; escritas coletivas permitem agregação e reordenação das requisições pela biblioteca MPI-IO.	6
2.3	Estrutura de cenários e estágios do SDDP. Cada célula corresponde a um subproblema (estágio, cenário). Os cenários são mutuamente independentes e podem ser distribuídos entre <i>ranks</i> MPI, caracterizando uma aplicação <i>bag-of-tasks</i> .	10
2.4	Comparação esquemática entre os formatos de resultados por parâmetros e horário do SDDP.	11
2.5	Arquitetura atual de E/S do SDDP com o <i>rank</i> 0 atuando como processo distribuidor e o <i>rank</i> 1 como processo escritor.	12
3.1	Arquitetura proposta com MPI-IO e Lustre, com o <i>rank</i> 0 atuando como processo distribuidor e os demais processos escrevendo diretamente em arquivos compartilhados.	14
3.2	Linha de tempo da simulação final do SDDP com MPI-IO, destacando o <i>rank</i> 0 como processo distribuidor.	15
3.3	Formato lógico dos arquivos binários de resultado do SDDP.	17
3.4	Fluxo de decisão para escritas independentes com MPI-IO.	18
4.1	Distribuição agregada da quantidade de blocos de dados por faixa de tamanho no experimento, em escala logarítmica.	26
4.2	Banda agregada média percebida pela aplicação no Experimento AWS.	31
4.3	Tempo de execução no Experimento AWS.	33
4.4	Tempo médio de bloqueio das operações de envio em função do tamanho dos blocos de dados no Experimento AWS (escala logarítmica).	34

4.5	Tempo médio de envio por classe de tamanho das mensagens para configurações MPI-IO com 4 e 10 OSTs.	36
4.6	Banda agregada média percebida pela aplicação na implementação MPI-IO para configurações com 4 e 10 OSTs em 16 e 32 nós.	37
4.7	Banda agregada média percebida pela aplicação nas implementações atual e MPI-IO no Experimento SDumont.	41
4.8	Decomposição do tempo médio por processo das implementações atual e MPI-IO no Experimento SDumont.	42
4.9	Tempo médio de bloqueio das operações de envio por tamanho de bloco de dados nas implementações atual e MPI-IO no Experimento SDumont (escala logarítmica).	44

Lista de Tabelas

2.1	Critérios práticos para escolha do modo de escrita em MPI-IO.	7
3.1	Arquivos de <i>log</i> gerados pela instrumentação, por <i>rank p</i>	20
4.1	Desempenho do Experimento AWS com a implementação atual, incluindo tempos de I/O, comunicação, tempo total, <i>speedup</i> , eficiência e percentual de I/O. A eficiência é calculada em relação à base de 2 nós.	28
4.2	Desempenho do Experimento AWS com a implementação MPI-IO, incluindo tempos de I/O, comunicação, coordenação, tempo total, <i>speedup</i> , eficiência e percentual de I/O. A eficiência é calculada em relação à base de 2 nós.	29
4.3	Resumo comparativo entre a implementação atual e MPI-IO no Experimento AWS. A melhoria no total e a melhoria de I/O são calculadas em relação à implementação atual; valores negativos indicam piora.	29
4.4	Desempenho do Experimento SDumont com a implementação atual. O tempo total corresponde ao tempo de execução medido, que inclui computação, E/S e comunicação. A eficiência é calculada em relação à base de 2 nós.	38
4.5	Desempenho do Experimento SDumont com a implementação MPI-IO. O tempo total corresponde ao tempo de execução medido, que inclui computação, E/S, comunicação e Coordenação MPI-IO. A eficiência é calculada em relação à base de 2 nós.	39
4.6	Resumo comparativo entre a implementação atual e MPI-IO no Experimento SDumont. A melhoria no total e a melhoria de I/O são calculadas em relação à implementação atual; valores negativos indicam piora.	40

Lista de Abreviaturas

AWS	Amazon Web Services	3
E/S	Entrada/Saída	1
EFA	Elastic Fabric Adapter	3
FSx	Amazon FSx for Lustre	3
HPC	High-Performance Computing	1
LNCC	Laboratório Nacional de Computação Científica	3
MDS	Metadata Server	3
MDT	Metadata Target	3
MPI	Message Passing Interface	1
MPI-IO	MPI Input/Output	3
ONS	Operador Nacional do Sistema Elétrico	3
OSS	Object Storage Server	3
OST	Object Storage Target	3
PMO	Programa Mensal da Operação	3
RDMA	Remote Direct Memory Access	3
SDDP	Stochastic Dual Dynamic Programming	1
SIN	Sistema Interligado Nacional	3
SINAPAD	Sistema Nacional de Processamento de Alto Desempenho	3

Capítulo 1

Introdução

O aumento da complexidade e do volume de dados em aplicações científicas e de engenharia tem tornado a computação paralela uma ferramenta indispensável para atender às demandas de desempenho KANG *et al.* (2020). Entretanto, operações de entrada e saída (E/S) continuam sendo um dos principais gargalos em ambientes de alto desempenho (HPC), particularmente em aplicações que processam dados massivos LUU *et al.* (2015); XIE *et al.* (2020). Nesse contexto, o uso de bibliotecas como o MPI-IO, combinadas com sistemas de arquivos paralelos como o Lustre, tornou-se uma abordagem fundamental para lidar com a escalabilidade e a eficiência no acesso aos dados MESSAGE PASSING INTERFACE FORUM (2025); OPENSFS AND EOFS (2025).

Paralelamente, a crescente inserção de fontes renováveis na matriz energética, como solar e eólica, tem introduzido novas dificuldades na formulação e resolução de problemas de otimização associados à operação dos sistemas elétricos. A variabilidade e incerteza dessas fontes requerem modelos computacionais mais complexos e dependentes de grandes volumes de dados, cuja execução eficiente depende tanto do paralelismo computacional quanto de soluções eficazes de E/S CONEJO *et al.* (2010); ZAKARIA *et al.* (2020).

ToDp: precisamos expandir esse parágrafo, explicar o que implica essa mudança de paradigma na simulação tanto para o uso de recursos computacionais como para o uso dos resultados pelos usuários do SDDP.

Assim como outras aplicações baseadas em tarefas independentes, o modelo SDDP (*Stochastic Dual Dynamic Programming*) é amplamente utilizado para planejamento e despacho hidrotérmico em diversos países. À medida que os modelos se tornam mais detalhados, em resolução horária, e a quantidade de cenários aumenta, a execução do SDDP passa a demandar não apenas alto poder computacional, mas também operações intensivas de E/S PEREIRA e PINTO (1991).

Nesse contexto, esta dissertação investiga o desempenho do MPI-IO sobre sistemas de arquivos paralelos como o Lustre nessa classe de aplicações, com foco no

comportamento da E/S em ambientes HPC.

Esta dissertação concentra-se na fase de simulação final do SDDP — etapa executada após a convergência da política de operação, na qual um conjunto fixo de cortes de Benders é avaliado em larga escala sobre múltiplos cenários para produzir os resultados operacionais entregues ao planejamento. As escolhas algorítmicas relacionadas à construção da política (fase iterativa de geração de cortes) estão fora do escopo deste trabalho.

ToDp: Apresentar organização da dissertação ao final da introdução (capítulos 2–5).

Capítulo 2

Fundamentação Teórica

2.1 MPI, protocolos de comunicação e operações paralelas de arquivos

O *Message Passing Interface* (MPI) é o padrão dominante para programação paralela baseada em processos que se comunicam por troca de mensagens. Em aplicações científicas executadas em *clusters* e supercomputadores, o MPI fornece tanto primitivas de comunicação ponto a ponto, como `MPI_Send` e `MPI_Recv`, quanto operações coletivas, como reduções, barreiras e difusões. A partir do MPI-2, o padrão também passou a incluir a especificação MPI-IO, que estende o mesmo modelo de coordenação entre processos para operações paralelas de entrada e saída em arquivos MESSAGE PASSING INTERFACE FORUM (2023, 1997).

Essa integração é importante porque comunicação e E/S não são problemas independentes em aplicações HPC. Uma arquitetura que concentra resultados em um único processo escritor transforma a E/S em comunicação ponto a ponto: os processos produtores enviam seus dados para um processo central, e esse processo serializa a escrita no sistema de arquivos. Por outro lado, uma arquitetura baseada em MPI-IO permite que os próprios processos produtores escrevam seus resultados, deslocando o gargalo do processo escritor para o sistema de arquivos paralelo. A escolha entre essas estratégias depende do tamanho das mensagens, do padrão de acesso aos dados, da regularidade dos deslocamentos no arquivo e da capacidade do sistema de armazenamento de atender requisições concorrentes.

No contexto da comunicação ponto a ponto, o comportamento de uma chamada de envio não é determinado apenas pela semântica da função usada pela aplicação, mas também pelo protocolo escolhido internamente pela biblioteca. Dois protocolos são particularmente relevantes: *eager* e *rendezvous*. No protocolo *eager*, a implementação envia pequenos blocos de dados de forma imediata, normalmente copiando-os para *buffers* internos até que o receptor execute a chamada correspondente. Esse

caminho favorece baixa latência para mensagens pequenas, pois evita uma etapa prévia de negociação, mas consome memória proporcional ao número de mensagens em trânsito.

No protocolo *rendezvous*, usado tipicamente para blocos maiores, o emissor primeiro negocia com o receptor antes da transferência efetiva dos dados. Esse *handshake* aumenta a latência inicial, porém reduz a necessidade de *buffers* intermediários e torna o consumo de memória mais previsível em cargas intensivas GROPP *et al.* (1999); THAKUR *et al.* (2005). Assim, mensagens pequenas e frequentes tendem a se beneficiar do *eager*, enquanto mensagens grandes favorecem o *rendezvous*, especialmente quando a aplicação opera próxima aos limites de memória ou de rede.

A Figura 2.1 resume essa relação entre comunicação ponto a ponto e E/S paralela. O fluxo centralizado usa a rede para mover os resultados até um escritor único; o fluxo MPI-IO remove essa etapa intermediária e permite que os processos escrevam diretamente em regiões distintas do arquivo.




Figura 2.1: Relação entre comunicação ponto a ponto e E/S paralela. No modelo centralizado, os resultados passam por um processo escritor; no modelo MPI-IO, os próprios processos escrevem diretamente no arquivo.

Para operações paralelas de arquivos, o MPI-IO define uma API padronizada para que múltiplos processos acessem arquivos compartilhados de forma coordenada. As operações podem ser classificadas, de maneira prática, em três grupos: escritas independentes, escritas coletivas e escritas não bloqueantes ou assíncronas. Cada grupo tem custos e benefícios distintos, e a escolha correta depende do padrão de dados produzido pela aplicação.

Do ponto de vista do arquivo, dois padrões de acesso são particularmente relevantes: acesso contíguo e acesso com *strides*. No acesso contíguo, cada processo

lê ou escreve uma região contínua do arquivo, como um bloco de resultados armazenado sequencialmente. Esse padrão é favorável ao sistema de arquivos paralelo, pois tende a gerar requisições maiores, alinhadas e com menor sobrecarga de metadados. No acesso com *strides*, por outro lado, os dados de um processo aparecem em regiões separadas por intervalos regulares, como ocorre em matrizes distribuídas por linhas, colunas ou blocos intercalados. Embora esse padrão represente de forma natural muitas estruturas científicas, ele pode produzir várias requisições pequenas e espaçadas quando tratado de maneira ingênua. O MPI-IO permite descrever esses acessos não contíguos por meio de tipos derivados e *file views*, possibilitando que a biblioteca reorganize a E/S por técnicas como *data sieving* e *two-phase I/O MESSAGE PASSING INTERFACE FORUM* (2023); ROSS *et al.* (2010); THAKUR *et al.* (1999a).

Nas escritas independentes, cada processo executa sua própria chamada de E/S sem exigir que os demais processos participem da mesma operação. Um exemplo típico é `MPI_File_write_at`, no qual o processo informa o *offset* do arquivo em que seus dados devem ser gravados. Esse padrão é adequado quando cada processo produz blocos naturalmente independentes, quando os tamanhos variam entre processos ou quando a aplicação não possui pontos convenientes de sincronização global. Também é uma escolha simples e robusta para aplicações do tipo *bag-of-tasks* CIRNE *et al.* (2003), em que tarefas independentes terminam em momentos diferentes e podem persistir seus resultados sem aguardar as demais.

O custo das escritas independentes é que o sistema de arquivos pode receber muitas requisições pequenas, desalinhadas ou concorrentes. Em sistemas paralelos como o Lustre, isso pode funcionar bem quando os blocos são suficientemente grandes e os *offsets* estão bem distribuídos entre *stripes* e OSTs. Entretanto, quando muitos processos escrevem pequenas regiões dispersas, a sobrecarga de metadados e a contenção nos servidores de armazenamento podem limitar a escalabilidade.

Nas escritas coletivas, todos os processos de um comunicador participam da mesma operação, como em `MPI_File_write_all`. Nesse caso, a biblioteca MPI-IO tem uma visão global dos acessos e pode reorganizar a E/S por meio de técnicas como *two-phase I/O*, agregação de requisições e *data sieving*. Em vez de cada processo enviar pequenas escritas diretamente ao sistema de arquivos, alguns processos agregadores podem reunir dados de vários processos e emitir operações maiores, mais contíguas e melhor alinhadas ao particionamento do arquivo.

Esse padrão é recomendado quando a aplicação possui fases bem definidas de produção de dados, quando todos ou quase todos os processos escrevem em uma mesma etapa e quando os acessos formam uma estrutura regular no arquivo, como matrizes distribuídas, campos de simulação em grades, *checkpoints* globais e saídas por passo de tempo. A escrita coletiva tende a reduzir o número de chamadas ao

sistema de arquivos e pode aumentar a banda efetiva, mas introduz sincronização entre processos. Se alguns deles produzem pouco dado, atrasam a chegada à chamada coletiva ou têm padrões de acesso muito irregulares, a operação coletiva pode aumentar o tempo de espera e prejudicar a sobreposição com a computação.

O MPI-IO também oferece variantes não bloqueantes, como `MPI_File_iwrite_at` e `MPI_File_iwrite_all`. Nessas operações, a chamada inicia a E/S e retorna antes de sua conclusão, permitindo que a aplicação execute computação ou comunicação enquanto a escrita progride. A conclusão é verificada posteriormente por chamadas como `MPI_Wait` ou `MPI_Test`. Esse modelo é útil quando há trabalho computacional independente logo após a geração dos dados, pois permite sobrepor parte do custo de E/S com computação. Contudo, operações assíncronas não eliminam o custo da escrita: elas apenas mudam o ponto em que a aplicação espera por sua conclusão. Além disso, a aplicação precisa preservar os *buffers* até o término da operação e controlar o número de escritas pendentes para evitar pressão excessiva de memória ou filas de E/S.

A Figura 2.2 contrasta os dois padrões principais de escrita. Na escrita independente, cada processo emite sua própria operação diretamente para o arquivo. Na escrita coletiva, a biblioteca MPI-IO coordena os processos e pode transformar várias requisições pequenas em operações agregadas.




Figura 2.2: Diferença entre escritas independentes e coletivas em MPI-IO. Escritas independentes preservam autonomia dos processos; escritas coletivas permitem agregação e reordenação das requisições pela biblioteca MPI-IO.

Tabela 2.1: Critérios práticos para escolha do modo de escrita em MPI-IO.

Modo de escrita	Padrão de aplicação mais adequado
Independente	Tarefas independentes, tamanhos de dados variáveis, término assíncrono dos <i>ranks</i> , <i>offsets</i> conhecidos, blocos contíguos por processo e baixa necessidade de sincronização global.
Coletiva	Fases globais de saída, dados regulares ou quase regulares, muitos acessos pequenos ou com <i>strides</i> que podem ser agregados, <i>checkpoints</i> e matrizes ou campos distribuídos.
Assíncrona independente	Aplicações com trabalho local após a geração dos dados e escritas por processo que podem progredir em segundo plano sem exigir participação imediata dos demais processos.
Assíncrona coletiva	Aplicações com fases coletivas bem definidas e computação útil após o início da E/S, desde que os <i>buffers</i> possam permanecer válidos até a conclusão da operação.

2.2 Sistema de arquivos paralelo Lustre

Projetado especificamente para cargas massivas de HPC, ele distribui os dados em *Object Storage Targets* (OSTs) e os metadados em *Metadata Servers* (MDS), permitindo acesso paralelo e balanceado a múltiplos clientes. Além disso, o Lustre utiliza a técnica de *striping*, na qual um arquivo é dividido em blocos (*chunks* ou *stripes*) distribuídos entre diferentes OSTs. O tamanho do *stripe* e o número de OSTs utilizados podem ser configurados de acordo com o padrão de acesso da aplicação, influenciando diretamente no *throughput* e na escalabilidade: *stripes* maiores tendem a favorecer grandes operações sequenciais, enquanto *stripes* menores podem beneficiar acessos concorrentes e distribuídos BRAAM (2002). Graças a essa flexibilidade e alto desempenho, o Lustre tornou-se amplamente adotado em supercomputadores listados no TOP500, constituindo um elemento-chave para aplicações científicas e industriais que exigem desempenho extremo em E/S.

2.3 Adaptadores de rede em HPC: Ethernet e InfiniBand

Os adaptadores de rede são componentes críticos para o desempenho em sistemas de computação de alto desempenho, sendo a Ethernet e o InfiniBand as tecnologias

mais utilizadas. A Ethernet, tradicionalmente projetada para redes locais corporativas, evoluiu para padrões de alta velocidade, como 40/100/400 Gbps, oferecendo elevada taxa de transferência (*bandwidth*), embora apresente latências relativamente maiores, frequentemente na ordem de dezenas de microssegundos. Já o InfiniBand foi desenvolvido especificamente para ambientes de HPC, combinando altas larguras de banda — que podem ultrapassar 400 Gbps em implementações modernas — com latências extremamente baixas, tipicamente abaixo de $2\ \mu\text{s}$, graças a recursos como comunicação RDMA (*Remote Direct Memory Access*). Essa diferença torna o InfiniBand preferido em supercomputadores e *clusters* científicos, onde a baixa latência na troca de dados entre processos é tão relevante quanto a banda disponível, enquanto a Ethernet, pelo menor custo e ampla compatibilidade, mantém espaço em sistemas híbridos e *datacenters* PETRINI *et al.* (2003); GRAHAM *et al.* (2005).

2.4 Computação em nuvem para HPC: AWS

A Amazon Web Services (AWS) tem se consolidado como uma das principais plataformas de computação em nuvem para aplicações de *High Performance Computing* (HPC), oferecendo recursos sob demanda que permitem a execução de cargas de trabalho intensivas em computação e E/S. Entre os serviços disponíveis, destacam-se as instâncias otimizadas para HPC, como as famílias C, H e P, que fornecem alto poder de processamento aliado a interconexões de baixa latência por meio do *Elastic Fabric Adapter* (EFA), permitindo a utilização de bibliotecas como MPI em escala. Para atender aplicações intensivas em dados, a AWS integra sistemas de armazenamento de alto desempenho, como o Amazon FSx for Lustre, que viabiliza acesso paralelo e em larga escala, semelhante a sistemas de arquivos utilizados em supercomputadores tradicionais. Essa combinação de infraestrutura elástica, rede de alto desempenho e suporte a ferramentas amplamente usadas em HPC torna a nuvem da AWS uma alternativa competitiva frente a *clusters* locais, especialmente em cenários que demandam escalabilidade e flexibilidade JACKSON *et al.* (2010); TRAN e THEKKEDATH (2020).

2.5 O Programa Mensal da Operação (PMO)

No setor elétrico brasileiro, o Programa Mensal da Operação (PMO) é um documento técnico elaborado pelo Operador Nacional do Sistema Elétrico (ONS) que estabelece as diretrizes de curto prazo para a operação do Sistema Interligado Nacional (SIN). O PMO contempla projeções de carga, disponibilidade de geração, restrições de transmissão e condições hidrológicas, servindo como referência para a programação da operação hidrotérmica de forma a garantir o equilíbrio entre oferta e

demanda de energia elétrica. Além disso, define metas de despacho de usinas hidrelétricas e termelétricas, contribuindo para a segurança energética e para a otimização do uso dos recursos disponíveis. Por sua relevância, o PMO orienta não apenas as decisões operativas do ONS, mas também agentes do setor, incluindo geradores, comercializadores e distribuidores, sendo um instrumento fundamental para a gestão integrada e eficiente do SIN OPERADOR NACIONAL DO SISTEMA ELÉTRICO (2023).

2.6 Algoritmo SDDP

O algoritmo SDDP (*Stochastic Dual Dynamic Programming*), proposto por PEREIRA e PINTO (1991), decompõe o problema de planejamento hidrotérmico em uma malha bidimensional de subproblemas determinísticos: cada subproblema é indexado por um par (estágio, cenário), em que os estágios representam períodos discretos da operação — meses, no caso da operação programada do SIN — e os cenários representam realizações estocásticas das variáveis relevantes, principalmente afluências aos reservatórios. A solução do problema é construída em duas fases. Na fase de *convergência*, iterações *forward/backward* constroem progressivamente uma política de operação representada por um conjunto de cortes de Benders, até atingir um critério de convergência. Na fase de *simulação final*, executada após a convergência, a política já fixa é avaliada em larga escala sobre um conjunto amplo de cenários para produzir os resultados operacionais entregues ao planejamento — variáveis primais, multiplicadores duais, custos e despachos. Esta dissertação concentra-se exclusivamente na fase de simulação final.

Nessa fase, os cenários são, por construção, mutuamente independentes: cada cenário corresponde a uma realização estocástica distinta, avaliada sob a mesma política convergida, sem compartilhamento de estado nem coordenação durante a execução. Essa propriedade caracteriza a fase de simulação final do SDDP como uma aplicação do tipo *bag-of-tasks* CIRNE *et al.* (2003): um conjunto de tarefas mutuamente independentes que podem ser distribuídas entre processadores sem sincronização durante a execução. Os cenários são particionados entre os *ranks* MPI e resolvidos em paralelo, de modo que o tempo total da fase de simulação fica limitado pelo cenário mais lento e não pela soma sequencial de todos. A natureza *bag-of-tasks* da fase de simulação é o que torna esta etapa do SDDP escalável em sistemas HPC; é também o que desloca o gargalo da computação para a persistência dos resultados, à medida que o número de cenários cresce.

Após a resolução, os resultados de cada subproblema — variáveis primais, multiplicadores duais e custos — precisam ser persistidos em disco, pois alimentam etapas subsequentes do próprio algoritmo e análises estatísticas posteriores.

A granularidade temporal adotada para os resultados de cada estágio tem impacto direto sobre o volume de dados produzido por iteração. A abordagem tradicional do SDDP agrega a operação dentro de cada estágio em poucos blocos representativos de carga (*patamares*: pesado, médio e leve), reduzindo cada estágio a um pequeno número de pontos operativos por cenário. A operação programada moderna, entretanto, especialmente com a crescente penetração de fontes intermitentes como solar e eólica, requer resolução horária para capturar adequadamente horários de ponta, vales e rampas associadas à variabilidade dessas fontes. Esta dissertação foca exatamente no regime de resultados horários, em que cada estágio de um cenário gera dados proporcionais ao número de horas simuladas — ordem de magnitude maior que o caso tradicional por blocos. É nesse regime que o gargalo de E/S se torna efetivamente dominante: o volume agregado escrito por iteração cresce linearmente com o número de cenários, com o número de estágios e com a granularidade temporal interna de cada estágio, e a estratégia de implementação dessas escritas determina diretamente a escalabilidade da aplicação em ambientes HPC.




Figura 2.3: Estrutura de cenários e estágios do SDDP. Cada célula corresponde a um subproblema (estágio, cenário). Os cenários são mutuamente independentes e podem ser distribuídos entre *ranks* MPI, caracterizando uma aplicação *bag-of-tasks*.

2.6.1 Comparação dos formatos dos resultados

Os resultados produzidos pelo SDDP são organizados em arquivos associados aos estágios, cenários e elementos do sistema elétrico. Cada elemento corresponde a uma entidade física ou lógica modelada na base de dados do sistema elétrico, como usinas hidrelétricas, usinas térmicas, reservatórios, barras, interligações ou outros componentes cujas grandezas sejam registradas na saída da simulação. Assim, a estrutura dos arquivos depende tanto da granularidade temporal adotada quanto da quantidade de elementos representados no sistema analisado.

No formato por *patamares*, os resultados de cada par (estágio, cenário) são agre-

gados em poucos blocos representativos de carga, como pesado, médio e leve. Esse formato reduz o número de registros por estágio e cenário, mas também limita a resolução temporal disponível para análises posteriores. No formato horário, por outro lado, cada estágio é detalhado em horas individuais. Para um estágio mensal de 30 dias, por exemplo, cada par (estágio, cenário) pode gerar 720 registros, um para cada hora, aumentando significativamente o volume de dados produzido.

Em ambos os formatos, os registros mantêm colunas de identificação seguidas pelos valores dos elementos do sistema elétrico. A diferença principal está na dimensão temporal interna ao estágio: no formato por patamares, essa dimensão é representada por um pequeno conjunto de blocos de carga; no formato horário, ela é representada por uma sequência de horas. A Figura 2.4 compara os dois formatos de maneira esquemática.

Formato por patamares						Formato horário					
estágio	cenário	patamar	E_1	$\dots$	E_N	estágio	cenário	hora	E_1	$\dots$	E_N
e_1	c_1	pesado	v_1	$\dots$	v_N	e_1	c_1	1	v_1	$\dots$	v_N
e_1	c_1	médio	v_1	$\dots$	v_N	e_1	c_1	2	v_1	$\dots$	v_N
e_1	c_1	leve	v_1	$\dots$	v_N	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\ddots$	$\vdots$
						e_1	c_1	720	v_1	$\dots$	v_N

Figura 2.4: Comparação esquemática entre os formatos de resultados por patamares e horário do SDDP.

2.6.2 Arquitetura atual de E/S do SDDP

Na arquitetura atual do SDDP, apenas um *rank* MPI (o *rank* 1, denominado processo escritor) é designado para realizar todas as operações de E/S do sistema. O *rank* 0 atua como processo distribuidor, coordenando o envio de tarefas e configurações aos demais *ranks*. Cada nó de computação, após resolver sua respectiva tarefa, envia os resultados por meio de um *buffer* de dados utilizando a função `MPI_Send`. Esse *buffer* é então recebido pelo processo escritor através de uma chamada `MPI_Recv` e, posteriormente, os dados são gravados em um sistema de arquivos distribuído. A Figura 2.5 ilustra o funcionamento dessa arquitetura.




Figura 2.5: Arquitetura atual de E/S do SDDP com o *rank* 0 atuando como processo distribuidor e o *rank* 1 como processo escritor.

Independentemente do número de nós computacionais utilizados, apenas um processo é responsável pelas operações de E/S. Cada nó utiliza sua banda efetiva para enviar os *buffers* de dados, enquanto o processo escritor utiliza sua banda para recebê-los. A primeira hipótese para as limitações de escalabilidade nessa arquitetura está relacionada ao adaptador de rede do servidor que executa o processo escritor.

Adicionalmente, o *rank* 0 é responsável pelo gerenciamento e controle da aplicação, como a distribuição de tarefas para os demais *ranks* e o envio/recebimento das configurações do sistema. Essas atividades também utilizam o mesmo adaptador de rede empregado na recepção dos *buffers* de dados. Outra hipótese é que o processo escritor opera continuamente em um fluxo sequencial de recepção e escrita dos dados, o que pode representar um gargalo adicional, sobretudo em sistemas com alto volume de dados. Por fim, se houver atrasos na recepção ou na gravação dos *buffers* de dados por parte do processo escritor, os nós computacionais podem ser obrigados a aguardar, gerando sobrecarga no envio dos *buffers* e aumentando o custo computacional da execução paralela.

Para efeitos desta dissertação, o *rank* 0 será referido como processo distribuidor, o *rank* 1 como processo escritor, e os demais *ranks*, responsáveis pela resolução dos cenários, como processos trabalhadores.

Capítulo 3

Paralelização dos Mecanismos de E/S do SDDP

Este capítulo apresenta a proposta de paralelização dos mecanismos de entrada e saída (E/S) do SDDP.

3.1 Visão geral da arquitetura

A solução substitui o modelo atual por uma organização baseada em MPI-IO sobre o sistema de arquivos Lustre. Nessa abordagem, cada processo grava diretamente seus próprios resultados em regiões independentes do espaço de saída, evitando a concentração das operações de E/S em um único processo.

O ponto central da proposta é explorar, simultaneamente, o paralelismo da aplicação MPI e o paralelismo do sistema de arquivos. Como os resultados produzidos por diferentes processos são independentes, suas escritas podem ser posicionadas previamente e executadas em paralelo. No Lustre, os arquivos são distribuídos em *stripes* entre diferentes *Object Storage Targets* (OSTs); assim, múltiplas escritas independentes podem ser atendidas por OSTs distintos, aumentando a largura de banda agregada e reduzindo a contenção observada no modelo com escritor centralizado.

Dessa forma, a proposta visa reduzir dois gargalos da arquitetura original. O primeiro é o gargalo de comunicação, pois os dados deixam de ser enviados ao processo escritor antes de serem persistidos. O segundo é o gargalo de armazenamento, pois a escrita passa a ser distribuída entre os recursos do sistema de arquivos paralelo, em vez de ser serializada por um único processo.

A Figura 3.1 apresenta uma visão geral da arquitetura proposta. O *rank* 0 atua como processo distribuidor, responsável por coordenar a distribuição das tarefas, enquanto os demais processos gravam seus resultados de forma independente sobre arquivos compartilhados. Nessa abstração, múltiplos processos operam concorren-

temente sobre o mesmo arquivo lógico em *offsets* distintos por meio das primitivas do MPI-IO MESSAGE PASSING INTERFACE FORUM (1997).




Figura 3.1: Arquitetura proposta com MPI-IO e Lustre, com o *rank* 0 atuando como processo distribuidor e os demais processos escrevendo diretamente em arquivos compartilhados.

3.2 Modelo de execução

A Figura 3.2 ilustra a linha do tempo da execução do SDDP segundo a arquitetura proposta. Essa representação destaca a separação entre os pontos de coordenação MPI-IO e o período em que os processos executam, de forma independente, a simulação dos cenários e a escrita dos respectivos resultados. Com isso, evidencia-se que a coordenação global fica concentrada nas etapas de preparação e finalização dos arquivos, enquanto o ciclo principal de processamento permanece distribuído entre os processos.

O processo distribuidor representa o *rank* 0, responsável por distribuir as tarefas aos demais *ranks*. Quando não está enviando uma nova tarefa, esse *rank* permanece aguardando o recebimento das tarefas concluídas pelos *ranks* trabalhadores. Por

esse motivo, sua linha é representada integralmente como comunicação.

Antes do início do ciclo de tarefas, os processos participam de uma operação coletiva de abertura dos arquivos de resultado. Esse ponto de coordenação MPI-IO estabelece o estado compartilhado necessário às escritas independentes que se seguem.

A partir desse momento, cada *rank* trabalhador executa o ciclo *bag-of-tasks* CIRNE *et al.* (2003): recebe do processo distribuidor uma tarefa correspondente a um cenário, resolve a simulação desse cenário e, ao término, efetua escritas independentes nos diversos arquivos de resultado, persistindo os blocos no formato proprietário do modelo SDDP. O tamanho de cada bloco varia conforme o arquivo de resultado produzido. Concluída a persistência, o processo solicita uma nova tarefa ao distribuidor, repetindo esse ciclo enquanto houver cenários disponíveis.

Quando não há mais cenários a serem resolvidos, inicia-se uma nova etapa de coordenação MPI-IO, dessa vez associada ao fechamento coletivo dos arquivos de resultado.




Figura 3.2: Linha de tempo da simulação final do SDDP com MPI-IO, destacando o *rank* 0 como processo distribuidor.

3.3 Detalhes de implementação

A implementação do SDDP é composta por módulos com responsabilidades distintas. Os módulos principais da aplicação, escritos em Fortran, controlam o fluxo de

execução da simulação e orquestram a chamada aos módulos de acesso a dados, enquanto os algoritmos de otimização são escritos em Mosel. Já os módulos de acesso a dados são implementados em C++, concentrando as rotinas de leitura e escrita dos arquivos de entrada e saída. Foi nesse ponto da arquitetura que a solução baseada em MPI-IO foi incorporada, substituindo o fluxo centralizado de escrita por operações paralelas realizadas diretamente pelos processos MPI. Essa separação permitiu introduzir a nova estratégia de E/S sem alterar a estrutura principal do algoritmo SDDP, preservando a lógica de simulação e restringindo as mudanças ao caminho de persistência dos resultados. Na prática, as rotinas MPI-IO são utilizadas para abrir os arquivos de resultado de forma compartilhada e permitir que cada processo grave diretamente os blocos produzidos pela simulação em posições previamente calculadas, conforme a organização lógica dos arquivos descrita a seguir.

3.3.1 Formato dos resultados

A implementação proposta preserva o formato dos arquivos de resultado utilizado pelo SDDP. Essa decisão foi adotada para manter a compatibilidade com a cadeia de softwares que consome esses arquivos em etapas posteriores do fluxo de trabalho. Assim, a mudança introduzida pela solução MPI-IO concentra-se na forma como os dados são gravados, sem alterar a estrutura lógica esperada pelos demais programas que dependem das saídas da simulação. Além disso, a manutenção do formato original permite estabelecer uma linha de base para comparações futuras com outras propostas de organização dos arquivos de resultado.

A Figura 3.3 detalha a organização lógica dos arquivos binários de resultado. Cada registro é identificado pelas três primeiras colunas, correspondentes ao estágio, ao cenário e à hora. A partir da quarta coluna são armazenados os valores associados aos elementos do sistema elétrico. Neste trabalho, um elemento do sistema elétrico corresponde a uma entidade física ou lógica modelada pelo SDDP e representada como uma coluna do arquivo de resultado. Esse elemento pode ser, por exemplo, uma usina hidrelétrica, uma usina térmica, um reservatório, uma barra, uma interligação ou qualquer outro componente do sistema elétrico cuja grandeza seja registrada na saída da simulação. Os valores desses elementos variam em função da combinação (estágio, cenário, hora). Essa estrutura permite calcular diretamente a região de escrita de cada cenário no arquivo. Os marcadores laterais indicam os *offsets* de início de cada estágio.

Estágios	Cenários	Hora	Elemento 1	Elemento 2	Elemento 3	...	Elemento N
1	1	1	142.37	88.04	317.92	...	51.68
1	1	2	139.85	91.27	305.44	...	49.13
...	...	...	...	...	...	...	...
2	1	1	156.20	74.66	288.09	...	63.41
...	...	...	...	...	...	...	...
E	S	H	121.09	96.58	334.71	...	57.24

Colunas de identificação do registro

Valores gravados a partir da coluna 4

Figura 3.3: Formato lógico dos arquivos binários de resultado do SDDP.

O número de elementos presentes em cada arquivo de resultado pode variar substancialmente de acordo com a base de dados do sistema elétrico analisado, pois cada sistema possui sua própria estrutura de equipamentos e componentes representados no modelo. Como cada elemento corresponde a uma coluna adicional no arquivo, essa variação também altera o tamanho dos blocos de dados gravados. Por exemplo, considerando um bloco horário associado a um par (estágio, cenário), com 720 horas e valores de 4 bytes, um arquivo com 1 elemento possui 4 colunas — estágio, cenário, hora e o valor do elemento —, totalizando aproximadamente 11,25 KB. Com 10 elementos, o bloco passa a ter 13 colunas e ocupa 36,56 KB. Já com 300 elementos, o bloco possui 303 colunas e ocupa 852,19 KB. Além disso, alguns resultados podem registrar apenas uma única hora, gerando blocos de dados ainda menores. Dessa forma, a estrutura física do sistema elétrico modelado influencia diretamente o volume de dados produzido e, consequentemente, o tamanho das escritas realizadas.

3.3.2 Implementação das escritas independentes

Como a simulação de cada cenário transcorre de forma independente, a abordagem baseada em MPI-IO permite que cada operação de escrita também seja independente: cada processo grava em um *offset* específico, determinado pelo cenário resolvido, sem necessidade de sincronização explícita entre escritas concorrentes.

A implementação adota escritas independentes de MPI-IO, combinando chamadas assíncronas e síncronas conforme o tamanho do bloco de dados. Para blocos menores que 128 KB, são utilizadas operações assíncronas, permitindo que o processo solicite a escrita e retome a execução sem aguardar imediatamente a conclusão da operação. Para blocos iguais ou superiores a 128 KB, são utilizadas operações síncronas, nas quais o processo aguarda a conclusão da escrita antes de prosseguir. Essa escolha segue uma lógica análoga à distinção entre os protocolos Eager e Rendezvous em comunicação MPI: blocos pequenos tendem a ser tratados de forma mais direta, com menor custo de coordenação, enquanto blocos maiores justificam um fluxo mais controlado, reduzindo o risco de acúmulo de requisições pendentes e de pressão sobre buffers internos.

A Figura 3.4 resume o fluxo de decisão adotado na implementação. Após o cálculo do *offset* correspondente ao cenário, o tamanho do bloco determina a rotina de escrita utilizada: blocos menores que 128 KB seguem pelo caminho assíncrono, enquanto blocos iguais ou superiores a esse limite seguem pelo caminho síncrono.




Figura 3.4: Fluxo de decisão para escritas independentes com MPI-IO.

Essa estratégia também facilita a comparação com a implementação atual. Como a arquitetura original já apresenta comportamento distinto para mensagens de tamanhos diferentes, separar os blocos pequenos e grandes na implementação MPI-IO permite avaliar a nova solução sob uma lógica compatível com o perfil de comunicação observado anteriormente, isolando melhor o impacto da mudança no mecanismo de escrita.

Como cada cenário ocupa um *offset* próprio em cada arquivo de resultado, elimina-se o risco de escritas concorrentes incidirem sobre uma mesma região. Essa propriedade constitui um benefício relevante da implementação proposta, pois dispensa o emprego de mecanismos de bloqueio (*locks*) para assegurar a corretude das operações concorrentes. Na implementação, o *offset* de cada escrita é calculado a partir da posição lógica do cenário no arquivo, do tamanho do registro associado à combinação (estágio, cenário, hora) e da quantidade de elementos do sistema elétrico armazenados em cada registro.

3.4 Considerações de configuração

No Lustre, cada bloco gravado nos arquivos de resultado é alocado em um *stripe* específico de um OST. Quando o volume acumulado ultrapassa o tamanho configurado para o *stripe*, um novo *stripe* é alocado em outro OST. A atribuição dos *stripes* aos OSTs ocorre de forma circular (*round-robin*), de modo que cada arquivo de resultado é fisicamente distribuído entre os múltiplos *stripes* alocados em OSTs distintos. Esse padrão permite paralelizar as operações de escrita sobre um mesmo arquivo, com grau de paralelismo limitado pelo número de OSTs definido na configuração de *striping* associada ao arquivo OPENSFS AND EOFS (2025).

Dois parâmetros são centrais nessa configuração. O primeiro é **stripe_count**, que define a quantidade de OSTs usados por arquivo e, portanto, o grau máximo de distribuição física das escritas. O segundo é **stripe_size**, que define o tamanho de cada faixa antes que o arquivo avance para o próximo OST. Valores muito baixos de **stripe_size** podem aumentar a fragmentação das requisições, enquanto valores muito altos podem reduzir a distribuição efetiva entre OSTs. A escolha desses parâmetros deve considerar o tamanho típico dos blocos gravados pelo SDDP e a concorrência esperada entre os *ranks*.

A escolha entre escritas independentes e coletivas favorece a primeira pelo modelo *bag-of-tasks*: cada *rank* persiste seus resultados assim que conclui o cenário recebido. Escritas coletivas poderiam permitir agregação interna pela biblioteca MPI-IO, mas exigiriam que múltiplos *ranks* participassem conjuntamente da mesma chamada de E/S. Nesse contexto, a sincronização adicional poderia bloquear *ranks* que já concluíram sua simulação enquanto aguardam outros cenários ainda em execução. Por esse motivo, a escrita independente é a escolha mais aderente ao padrão de execução avaliado.

3.5 Instrumentação

A avaliação empírica apresentada no Capítulo 4 requer medições detalhadas dos tempos consumidos em cada etapa do ciclo de execução do SDDP. Para isso, tanto a implementação atual quanto a implementação proposta foram instrumentadas no módulo de persistência do SDDP — o mesmo ponto da arquitetura no qual a solução baseada em MPI-IO foi incorporada (Seção 3). Os cronômetros foram posicionados imediatamente antes e depois das chamadas instrumentadas utilizando **MPI_Wtime**, primitiva da própria biblioteca MPI cuja resolução é adequada para temporização de operações de E/S e comunicação. Dessa forma, os tempos refletem exatamente o que cada processo observa em sua execução, sem interferência de relógios externos ou de ferramentas de *profiling* fora do espaço de memória da aplicação.

A instrumentação foi mantida coerente entre as duas implementações, de modo a permitir comparação direta. Cada métrica possui uma definição operacional única, aplicável tanto ao modelo centralizado — em que a transferência dos blocos de dados ocorre por `MPI_Send` e `MPI_Recv` até o *rank* escritor — quanto ao modelo MPI-IO, em que a transferência ocorre por chamadas a `MPI_File_write_at` e `MPI_File_iwrite_at`, conforme o tamanho do bloco de dados.

3.5.1 Registros gerados pela instrumentação

Os tempos coletados são persistidos em arquivos de *log* textuais gerados por *rank*, de forma a evitar contenção sobre um mesmo descritor de arquivo e a permitir consolidação *off-line*. A estratégia de gravação acumula os valores em memória durante a execução e os escreve em disco apenas ao final, fora da janela de medição, de modo a minimizar a perturbação introduzida pela própria instrumentação. A Tabela 3.1 sumariza os arquivos produzidos para cada *rank p*.

Tabela 3.1: Arquivos de *log* gerados pela instrumentação, por *rank p*.

Arquivo	Conteúdo
<code>mpio-{p}.log</code>	Um registro por operação de escrita do <i>rank p</i> , contendo estágio, cenário, identificador do arquivo, número de sequência, <i>timestamps</i> de início e fim da chamada (<code>MPI_File_write_at</code> ou <code>MPI_File_iwrite_at</code>) e tamanho do bloco em <i>bytes</i> .
<code>mpio-collective-{p}.log</code>	Um registro por operação coletiva de E/S, com tipo (<code>open</code> ou <code>close</code>), nome do arquivo e <i>timestamps</i> de início e fim da chamada (<code>MPI_File_open</code> ou <code>MPI_File_close</code>).
<code>mpio-{p}-wait.log</code>	Tempo acumulado em que o <i>rank p</i> permaneceu bloqueado aguardando a liberação dos <i>slots</i> de <i>buffer</i> utilizados pelas escritas assíncronas (<code>MPI_Wait</code> obrigatório quando ambos os <i>slots</i> estão ocupados).
<code>sddptimer{p}.log</code>	Temporizadores internos do SDDP, em particular <i>Simulation</i> — tempo total da fase de simulação — e <i>Hourly simulation</i> — tempo gasto especificamente no trabalho de resolução horária dos cenários, sem chamadas MPI.

A partir desses arquivos, as métricas são derivadas por agregação. As subseções seguintes descrevem cada métrica em termos das grandezas medidas e do significado físico que carregam para a análise de desempenho.

3.5.2 Tempo de computação

Corresponde ao tempo gasto por cada *rank* no trabalho útil da aplicação — a resolução numérica dos cenários a ele atribuídos —, excluindo as chamadas MPI de coordenação e as operações de E/S. Esse intervalo é obtido a partir do temporizador `Hourly simulation` do `sddptimer{p}.log`, que delimita estritamente o trecho de código responsável pela simulação horária no SDDP.

Em um cenário de *strong scaling*, espera-se que esse tempo decresça aproximadamente de forma linear com o número de nós, dado que cada nó passa a processar uma fração menor do total de cenários. Desvios sistemáticos dessa tendência indicariam contenção indireta sobre recursos compartilhados (memória, *cache* ou rede) ou desbalanceamento entre os *ranks*, mas não devem ser sensíveis ao mecanismo de E/S adotado. O tempo de computação serve, portanto, como referência estável contra a qual os tempos de comunicação, de E/S e de coordenação podem ser comparados.

3.5.3 Tempo de coordenação MPI

Reúne os tempos despendidos em chamadas MPI que não correspondem à transferência dos blocos de dados em si, mas sim ao estabelecimento de pontos de coordenação entre processos. Estão incluídas, nessa categoria, as operações coletivas de abertura e fechamento dos arquivos de resultado (`MPI_File_open` e `MPI_File_close`), registradas no `mpioo-collective-{p}.log`. Por se tratar de operações coletivas exigidas pela semântica da biblioteca MPI-IO, são inerentes à implementação proposta e ausentes na implementação atual, que opera apenas com primitivas ponto a ponto.

Essa métrica é particularmente relevante para a arquitetura proposta, pois revela o custo embutido nas operações coletivas, que tende a crescer com o número de *ranks* participantes. Em escala, esse custo pode emergir como gargalo adicional, mesmo quando o tempo de E/S por *rank* se reduz MESSAGE PASSING INTERFACE FORUM (1997). Capturá-lo separadamente permite distinguir o ganho líquido da paralelização das escritas do custo adicional imposto pela própria coordenação coletiva.

3.5.4 Tempo total de E/S

Corresponde ao tempo total que cada *rank* dedica às operações associadas à persistência dos blocos de dados, calculado pela soma dos intervalos $T_e^{\text{io}} - T_s^{\text{io}}$ registrados no `mpioo-{p}.log`. Na implementação MPI-IO, esse tempo corresponde às chamadas `MPI_File_write_at` (síncronas, para blocos ≥ 128 KB) e `MPI_File_iwrite_at` (assíncronas, para blocos < 128 KB). Na implementação atual, embora o *rank* es-

critor concentre toda a escrita em disco, a contabilização inclui o tempo gasto pelos *ranks* trabalhadores nas chamadas `MPI_Send` responsáveis pelo encaminhamento dos blocos, de modo a tornar as duas instrumentações diretamente comparáveis.

A métrica caracteriza, de forma agregada, o custo computacional que a E/S representa para a aplicação, independentemente de o trabalho estar concentrado em um único processo ou distribuído entre todos. Diferenças entre as duas implementações nessa métrica refletem o impacto direto da paralelização das escritas sobre o caminho de persistência.

3.5.5 Tempo de bloqueio na transferência dos blocos de dados

Restringe-se ao intervalo em que o *rank* permanece efetivamente bloqueado aguardando a conclusão de uma transferência, sem condição de prosseguir com a execução subsequente. Na implementação proposta, essa parcela é registrada no `mpioo-{p}-wait.log` e corresponde, especificamente, ao tempo gasto em `MPI_Wait` quando ambos os *slots* do esquema de duplo *buffer* adotado pela implementação se encontram ocupados — único ponto em que o *rank* é obrigado a aguardar a finalização de uma escrita assíncrona antes de submeter a próxima. Para escritas síncronas, o tempo de bloqueio coincide com a duração total da chamada `MPI_File_write_at`, já contabilizada no tempo total de E/S.

A separação entre tempo total de E/S e tempo de bloqueio é especialmente relevante na análise de granularidade dos blocos. Para blocos pequenos, predominam custos fixos de iniciação e coordenação; para blocos grandes, predomina o tempo efetivo de transferência. O tempo de bloqueio, ao isolar a parcela perceptível como atraso pela aplicação, é o que efetivamente limita a sobreposição entre a computação e as operações de escrita. Em uma execução bem dimensionada, espera-se que esse tempo seja baixo, indicando que a estratégia assíncrona conseguiu mascarar a latência do subsistema de armazenamento. Crescimentos sistemáticos do tempo de bloqueio em função do número de *ranks* sugerem saturação dos recursos do sistema de arquivos ou contenção entre escritas concorrentes.

3.5.6 Banda agregada média percebida pela aplicação

Define-se, neste trabalho, como *banda agregada percebida pela aplicação* a métrica derivada que sintetiza, em uma única grandeza, quanto da capacidade de E/S disponível a aplicação SDDP efetivamente consegue aproveitar sob seu modelo de execução. Não se trata de uma grandeza canônica do contexto HPC, e sim de uma construção operacional adotada aqui para tornar mensurável o efeito da paralelização das escritas sobre o fluxo da aplicação na comparação entre as duas implementações investigadas. É calculada a partir dos registros do `mpioo-{p}.log` particionando-

se a fase de simulação em janelas de tempo de duração fixa Δ . Para cada janela w , computa-se a razão entre o volume total de dados gravados por todos os *ranks* naquele intervalo e o tempo de E/S acumulado pelo *rank* mais lento da janela:

$$B_w = \frac{\sum_{i=1}^P V_{i,w}}{\max_{i=1,\dots,P} T_{i,w}^{\text{E/S}}},$$

em que $V_{i,w}$ é o volume gravado pelo *rank* i na janela w , $T_{i,w}^{\text{E/S}}$ é o tempo de E/S acumulado por esse *rank* dentro da mesma janela e P é o número de processos. O denominador adota o tempo do processo mais lento, em consonância com o comportamento síncrono da aplicação ao final de cada janela: o avanço para a próxima etapa só é possível quando todos os *ranks* concluem suas escritas. O valor reportado para uma execução é a média aritmética de B_w ao longo das janelas que cobrem a fase de simulação, e a banda agregada média associada a uma configuração de nós corresponde à média dessa grandeza ao longo das cinco repetições realizadas para cada configuração, acompanhada do respectivo desvio padrão.

Banda percebida *versus* banda agregada real. É fundamental destacar que essa métrica, tal como definida nesta seção, caracteriza a banda *percebida pela aplicação* — conceito construído para os fins deste trabalho — e não a *banda agregada real* oferecida pelo sistema de arquivos paralelo, esta sim grandeza canônica do contexto HPC. A banda agregada real corresponde ao débito máximo que o subsistema de armazenamento — conjunto de OSTs, MDS, rede de interconexão e clientes Lustre — é capaz de sustentar e seria tipicamente obtida por meio de ferramentas de *benchmarking* dedicadas, como IOR, sob padrões de acesso idealizados (blocos grandes, alinhamento perfeito e ausência de contenção). Esse valor representa, em essência, um limite superior de referência para o sistema de armazenamento, mas não é diretamente observável pela aplicação SDDP.

A banda percebida, em contrapartida, mede o volume gravado em função do tempo em que a aplicação permanece efetivamente bloqueada nas operações de E/S. Para escritas síncronas (`MPI_File_write_at`), o intervalo registrado no `mpio-{p}.log` corresponde à duração integral da chamada, durante a qual o *rank* fica impedido de prosseguir. Para escritas assíncronas (`MPI_File_iwrite_at`), o intervalo registrado refere-se apenas ao despacho da operação — tipicamente desprezível —, de modo que escritas assíncronas bem-sucedidas não inflam o denominador. O tempo eventual de espera por `MPI_Wait`, que ocorre apenas quando os *slots* de duplo *buffer* estão ocupados, é contabilizado separadamente (Seção 3.5.5) e não compõe a banda percebida. Em consequência, a métrica captura especificamente a

parcela de sobrecarga que se traduz em bloqueio do caminho de execução: custos internos da biblioteca MPI-IO, contenção entre OSTs ou sincronizações implícitas que sejam mascaradas pelo paralelismo das escritas assíncronas não aparecem na medida. É esperado, portanto, que a banda percebida possa *superar* a banda agregada real do sistema de arquivos: a assincronia das escritas e o uso de *buffers* internos da pilha MPI e do sistema operacional mascaram parte da latência física de persistência, de modo que o volume gravado é contabilizado no numerador antes que o tempo correspondente de transferência efetiva apareça no denominador. A métrica reporta, assim, a taxa efetiva com que a aplicação consegue submeter dados sob seu modelo de execução, e não a vazão sustentada pelo subsistema de armazenamento.

A escolha por reportar a banda percebida está alinhada ao objetivo deste trabalho, que é avaliar quanto da capacidade disponível a aplicação consegue efetivamente aproveitar — e não caracterizar o sistema de arquivos isoladamente. Sob essa ótica, a métrica reflete o desempenho do subsistema de armazenamento *na medida em que ele bloqueia a aplicação*, capturando simultaneamente a vazão sustentada pela infraestrutura e a eficácia da estratégia de E/S em sobrepor escritas com computação. É essa combinação que a torna adequada para a comparação direta entre as duas implementações investigadas: uma estratégia que reduza o tempo de bloqueio — seja por paralelizar escritas em múltiplos OSTs, seja por mascará-las com chamadas assíncronas — eleva a banda percebida ainda que a banda agregada real do sistema permaneça inalterada.

Capítulo 4

Avaliações

Este capítulo apresenta a avaliação comparativa entre a implementação atual de entrada e saída (E/S) e a implementação proposta, com o objetivo de investigar ganhos de desempenho e melhorias de escalabilidade, principalmente em ambientes de computação em nuvem. A análise concentra-se em métricas de tempo de execução, tempo de comunicação, largura de banda e tempo de bloqueio das operações de E/S, considerando o impacto das estratégias adotadas para operações paralelas de E/S em cenários de alto desempenho THAKUR *et al.* (1999b); CARNS *et al.* (2009).

A base de dados utilizada nos experimentos corresponde ao PMO/PAR de outubro de 2023. Para a etapa de simulação horária, que constitui o foco principal deste estudo, foram considerados 1.536 cenários em ambos os experimentos (AWS e SDumont), com três estágios mensais.

Para cada configuração avaliada, foram executadas cinco repetições; os valores reportados nas tabelas e figuras deste capítulo correspondem à média e ao desvio padrão dessas amostras.

Como cada *rank* MPI apresentou consumo de memória residente superior a 8 GB, optou-se, em ambos os experimentos, por mapear apenas um *rank* por núcleo físico — isto é, sem o uso do *hyper-threading*. Essa decisão é imposta pela memória total disponível por nó: com 384 GB por nó nos dois ambientes, ativar *hyper-threading* e dobrar o número de *ranks* ultrapassaria a memória física agregada, inviabilizando a execução. O número de *ranks* por nó foi, portanto, fixado no número de núcleos físicos da instância correspondente.

Os experimentos conduzidos neste trabalho caracterizam um cenário de *strong scaling*, no qual o tamanho do problema permanece fixo enquanto o número de nós computacionais é progressivamente aumentado AMDAHL (1967). Nesse contexto, o acréscimo de recursos implica na redução do volume de trabalho por nó, sendo esperado, idealmente, que o tempo total de execução diminua de forma aproximadamente linear com o aumento do paralelismo. No entanto, essa tendência teórica pode não se concretizar na prática devido à presença de gargalos sistêmicos, especi-

almente aqueles relacionados às operações de entrada e saída (E/S) e à comunicação entre processos. À medida que o número de nós cresce, a intensificação da concorrência por recursos compartilhados — como o sistema de arquivos e a rede — pode introduzir sobrecargas adicionais, limitando a eficiência do escalonamento e reduzindo os ganhos esperados de desempenho.

O tamanho dos blocos de dados foi considerado um fator determinante para a análise de desempenho de E/S paralela. A Figura 4.1 apresenta a distribuição agregada do tamanho dos blocos de dados observados ao longo do experimento. Observa-se que a distribuição é dominada por blocos de dados pequenos: 1.801.728 blocos, correspondentes a 80,1% do total, possuem tamanho de até 1 KB. As demais faixas concentram 152.082 blocos até 128 KB (6,8%), 267.264 blocos até 1 MB (11,9%) e 27.648 blocos até 50 MB (1,2%). Esse perfil pode comprometer a escalabilidade, já que operações com granularidade fina tendem a aumentar a sobrecarga de metadados e a subutilizar a largura de banda disponível THAKUR *et al.* (1999b); CARNS *et al.* (2009). Adicionalmente, será avaliado o tempo de envio dos blocos de dados agrupados por faixas de tamanho, de forma a analisar o impacto da granularidade das operações no desempenho da comunicação e da E/S.




Figura 4.1: Distribuição agregada da quantidade de blocos de dados por faixa de tamanho no experimento, em escala logarítmica.

4.1 Experimento AWS

O Experimento AWS foi configurado na nuvem da Amazon Web Services (AWS), utilizando 32 nós da instância do tipo r7i.12xlarge. Essa instância é baseada na quarta geração de processadores Intel Xeon Scalable (Sapphire Rapids 8488C), operando a 3,2 GHz, e disponibiliza 24 núcleos físicos com suporte a *hyper-threading*,

totalizando 48 processadores lógicos. O sistema conta ainda com 384 GB de memória DDR5, que oferece maior largura de banda em relação às gerações anteriores, e um adaptador de rede Ethernet com capacidade de até 18,75 Gbps, projetado para cargas de trabalho intensivas em comunicação. Essa configuração enquadra-se na categoria de instâncias otimizadas para memória da AWS (*memory-optimized*), adequada a aplicações que combinam elevada demanda de processamento paralelo com grandes volumes de dados em memória — perfil característico do SDDP, em que cada *rank* MPI chega a consumir mais de 8 GB de memória residente. Nos experimentos, utilizou-se a biblioteca MPICH2 versão 3.2 e um sistema de arquivos paralelo Lustre versão 2.12 de 12 TB, com 1 MDS de 350 GB e 10 OSTs de 1,165 TB. O *stripe count* foi configurado como 10, com *stripes* de 1 MB, disponibilizado por meio do serviço Amazon FSx for Lustre. Pelos motivos discutidos na introdução do capítulo, configurou-se um *rank* por núcleo físico, totalizando 24 *ranks* MPI por nó, que processam cenários em paralelo segundo o padrão *bag-of-tasks* descrito na Subseção ?? INTEL CORPORATION (2023); AMAZON WEB SERVICES (2024).

4.1.1 Avaliação da implementação atual

Esta subseção analisa o desempenho da arquitetura atual de E/S do SDDP no Experimento AWS. A Tabela 4.1 sumariza os resultados obtidos com a base de dados PMO/PAR de outubro de 2023, considerando 1.536 cenários, três estágios mensais e 24 *ranks* por nó.

Observa-se que o tempo total de execução cai com o aumento do número de nós até 16 nós, passando de aproximadamente 8 971 s em 2 nós para 1 874 s em 16 nós, mas volta a crescer para 2 013 s em 32 nós — caracterizando o regime saturado típico de um cenário de *strong scaling* limitado pela E/S. A banda agregada degrada-se de 60,5 Gb/s em 2 nós para 3,4 Gb/s em 32 nós (mais de uma ordem de grandeza), e o percentual do tempo dedicado à E/S cresce de 0,34% em 2 nós para 49,51% em 32 nós. Esses números são coerentes com o diagnóstico de que o adaptador de rede do nó escritor se torna ponto de contenção à medida que aumenta o número de processos emissores concorrentes. Vale notar que a banda percebida em pequena escala (60,5 Gb/s em 2 nós) excede a capacidade nominal do adaptador de rede da r7i.12xlarge (18,75 Gb/s). Esse aparente excesso é consistente com a definição da métrica (Seção 3.5.6): em 2 nós, os blocos são absorvidos com bloqueio mínimo pelos *buffers* da pilha MPI e do sistema operacional, e o denominador da banda percebida fica reduzido. Conforme cresce o número de *ranks* emissores, o NIC do escritor satura, os bloqueios se acumulam e a banda percebida converge para valores muito inferiores à capacidade nominal do adaptador — exatamente o regime observado a partir de 8 nós.

Soma-se a esse efeito a heterogeneidade entre envios locais e remotos. Na implementação atual, os *ranks* trabalhadores transferem seus blocos ao *rank* escritor por meio de `MPI_Send`. Mesmo sendo síncrono, esse envio, quando emissor e receptor residem no mesmo nó, ocorre por canais de memória compartilhada da biblioteca MPI e apresenta tempo de bloqueio significativamente inferior ao dos envios remotos, que precisam atravessar o NIC do nó emissor e o do nó escritor. Esse efeito é particularmente acentuado na configuração de 2 nós, em que cerca de metade dos *ranks* trabalhadores reside no mesmo nó do escritor e produz envios locais — inflando ainda mais a banda percebida nessa escala. À medida que cresce o número de nós, a fração de envios locais diminui rapidamente (aproximadamente um quarto em 4 nós, um oitavo em 8 nós e abaixo de 6% em 16 nós), e o comportamento da métrica passa a refletir predominantemente o tempo de bloqueio das transferências remotas, governadas pela saturação do NIC do escritor.

Na Tabela 4.1, o tempo total corresponde ao tempo de execução medido, que inclui computação, E/S e comunicação. Os tempos de I/O e comunicação são apresentados separadamente.

Tabela 4.1: Desempenho do Experimento AWS com a implementação atual, incluindo tempos de I/O, comunicação, tempo total, *speedup*, eficiência e percentual de I/O. A eficiência é calculada em relação à base de 2 nós.

Nós	Banda percebida (Gb/s)	I/O (s)	% I/O	Comunicação (s)	Total (s)	Speedup	Eficiência (%)
2	60,51 ± 4,56	30,85 ± 2,05	0,34%	177,51 ± 26,06	8 971,23 ± 305,56	1,00×	100,0%
4	51,28 ± 2,48	78,23 ± 3,04	1,62%	212,76 ± 16,94	4 823,20 ± 46,53	1,86×	93,0%
8	18,94 ± 3,30	201,67 ± 4,13	7,64%	174,04 ± 11,31	2 639,18 ± 16,07	3,40×	85,0%
16	4,52 ± 0,29	527,94 ± 2,91	28,18%	167,77 ± 6,19	1 873,56 ± 49,91	4,79×	59,9%
32	3,37 ± 0,09	996,57 ± 5,28	49,51%	304,96 ± 3,36	2 013,06 ± 25,50	4,46×	27,9%

4.1.2 Avaliação da implementação MPI-IO com escritas independentes

Esta subseção analisa o desempenho da arquitetura proposta, baseada em escritas independentes com MPI-IO sobre o sistema de arquivos Lustre, no Experimento AWS. Nesta abordagem cada processo MPI escreve seus próprios dados diretamente no FSx for Lustre, eliminando o ponto de contenção associado a um único processo escritor e explorando o paralelismo dos múltiplos OSTs.

A Tabela 4.2 consolida os resultados obtidos com a implementação MPI-IO no Experimento AWS. Assim como na tabela anterior, o tempo total corresponde ao tempo de execução medido, que inclui computação, E/S, comunicação e Coordenação MPI-IO. Os tempos de I/O, comunicação e Coordenação MPI-IO são apresenta-

dos separadamente; a coordenação corresponde às chamadas `MPI_File_Open/MPI_File_Close`.

Tabela 4.2: Desempenho do Experimento AWS com a implementação MPI-IO, incluindo tempos de I/O, comunicação, coordenação, tempo total, *speedup*, eficiência e percentual de I/O. A eficiência é calculada em relação à base de 2 nós.

Nós	Banda percebida (Gb/s)	I/O (s)	% I/O	Comunicação (s)	Coord. (s)	Total (s)	Speedup	Eficiência (%)
2	57,04 ± 7,42	18,57 ± 0,86	0,21%	188,65 ± 22,49	42,48 ± 6,74	8 858,91 ± 97,68	1,00×	100,0%
4	106,04 ± 17,02	12,54 ± 0,38	0,24%	233,95 ± 21,24	51,23 ± 13,28	5 127,24 ± 94,25	1,73×	86,4%
8	167,03 ± 35,23	9,36 ± 0,32	0,36%	186,69 ± 18,47	69,82 ± 4,10	2 599,75 ± 32,55	3,41×	85,2%
16	274,24 ± 13,44	7,42 ± 0,10	0,48%	233,77 ± 4,50	83,53 ± 3,65	1 558,33 ± 8,23	5,68×	71,1%
32	380,30 ± 26,86	8,93 ± 0,08	0,70%	236,02 ± 8,15	147,26 ± 6,41	1 274,25 ± 20,95	6,95×	43,5%

4.1.3 Análise comparativa

Os resultados das duas subseções anteriores são consolidados visualmente nas figuras a seguir, que apresentam, lado a lado, os perfis de banda agregada, tempo de execução e tempo de bloqueio de envio em função do número de nós para as duas implementações.

A Tabela 4.3 resume os principais indicadores comparativos do Experimento AWS. A melhoria no tempo total é pequena em 2 nós, torna-se negativa em 4 nós, mas passa a ser positiva a partir de 8 nós e cresce nas maiores escalas: 1,5% em 8 nós, 16,8% em 16 nós e 36,7% em 32 nós. A comparação de banda evidencia o principal ganho da arquitetura proposta: a MPI-IO passa de desempenho ligeiramente inferior em 2 nós para 2,07× a banda da implementação atual em 4 nós, 8,82× em 8 nós, 60,66× em 16 nós e 113,00× em 32 nós. A redução do tempo de E/S também cresce com a escala, chegando a 99,1% em 32 nós.

Tabela 4.3: Resumo comparativo entre a implementação atual e MPI-IO no Experimento AWS. A melhoria no total e a melhoria de I/O são calculadas em relação à implementação atual; valores negativos indicam piora.

Nós	Total atual (s)	Total MPI-IO (s)	Melhoria no total (%)	Banda percebida atual (Gb/s)	Banda percebida MPI-IO (Gb/s)	Ganho de banda perc.	I/O atual (s)	I/O MPI-IO (s)	Melhoria I/O (%)
2	8 971,23	8 858,91	1,3%	60,51	57,04	0,94×	30,85	18,57	39,8%
4	4 823,20	5 127,24	-6,3%	51,28	106,04	2,07×	78,23	12,54	84,0%
8	2 639,18	2 599,75	1,5%	18,94	167,03	8,82×	201,67	9,36	95,4%
16	1 873,56	1 558,33	16,8%	4,52	274,24	60,66×	527,94	7,42	98,6%
32	2 013,06	1 274,25	36,7%	3,37	380,30	113,00×	996,57	8,93	99,1%

A Figura 4.2 apresenta a evolução da banda agregada média percebida pela aplicação no Experimento AWS. As duas curvas exibem comportamentos qualitativamente opostos: a implementação atual parte de aproximadamente 60,5 Gb/s em

2 nós e degrada-se de forma acentuada com o aumento do paralelismo, atingindo 18,9 Gb/s em 8 nós, 4,5 Gb/s em 16 nós e 3,4 Gb/s em 32 nós — uma redução de mais de uma ordem de grandeza. Em contraste, a implementação MPI-IO parte de 57,0 Gb/s em 2 nós e cresce monotonicamente, alcançando 106,0 Gb/s em 4 nós, 167,0 Gb/s em 8 nós, 274,2 Gb/s em 16 nós e 380,3 Gb/s em 32 nós.

Em 2 nós, a banda agregada da implementação atual é cerca de 6% maior que a da implementação MPI-IO. Esse comportamento é coerente com o fato de que, em pequena escala, o gargalo do processo escritor único ainda não se manifesta, e o custo fixo da coordenação da E/S paralela tem maior peso relativo. A partir de 4 nós, entretanto, a implementação MPI-IO já supera a atual. Em 8 nós, a banda agregada é aproximadamente $8,8\times$ maior; em 16 nós, cerca de $60,7\times$ maior; e, em 32 nós, aproximadamente $113,0\times$ maior. Esse resultado indica que a arquitetura proposta explora a infraestrutura de armazenamento em uma escala completamente diferente da arquitetura baseada em escritor único.

Essa diferença de comportamento decorre diretamente da eliminação do processo escritor único. Na arquitetura atual, todas as escritas convergem para o adaptador de rede de um único nó, que rapidamente se torna ponto de contenção e limita o *throughput* global — explicando a queda contínua da banda observada. Na abordagem MPI-IO, as operações de escrita são distribuídas entre os processos MPI, permitindo que múltiplos fluxos de dados sejam enviados simultaneamente ao sistema de arquivos Lustre, explorando o paralelismo proporcionado pelos múltiplos OSTs. Como consequência, a banda agregada cresce de forma consistente com o número de nós, demonstrando que o sistema de armazenamento ainda não atingiu seu limite nominal na maior configuração avaliada. Dessa forma, a figura evidencia que a adoção de MPI-IO não apenas elimina o gargalo da arquitetura atual, mas também permite um uso significativamente mais eficiente da largura de banda disponível, tornando a aplicação adequada para execuções em larga escala.




Figura 4.2: Banda agregada média percebida pela aplicação no Experimento AWS.

A Figura 4.3 apresenta a evolução do tempo total de execução no Experimento AWS, contrastando a implementação atual e a implementação MPI-IO sobre o Lustre. As barras de erro representam apenas o desvio padrão do tempo de execução total, e não desvios individuais das parcelas internas. Nas configurações de menor escala, em que a E/S não é o componente dominante, as duas curvas evoluem de forma próxima: em 2 nós, $8,97 \times 10^3$ s no modelo atual contra $8,86 \times 10^3$ s no modelo MPI-IO; em 4 nós, entretanto, a versão MPI-IO apresenta $5,13 \times 10^3$ s contra $4,82 \times 10^3$ s da implementação atual. Esse comportamento é coerente, uma vez que, em pequena escala, o tempo de execução é dominado pela computação e o custo da coordenação ainda tem maior peso relativo.

A divergência entre as duas curvas torna-se evidente a partir de 8 nós e se acentua de forma marcante nas configurações de maior porte. Enquanto a implementação atual apresenta um regime de saturação — com o tempo de execução passando de $2,64 \times 10^3$ s em 8 nós para $1,87 \times 10^3$ s em 16 nós e voltando a crescer para $2,01 \times 10^3$ s em 32 nós —, a implementação MPI-IO mantém uma redução consistente do tempo total, atingindo $2,60 \times 10^3$ s em 8 nós, $1,56 \times 10^3$ s em 16 nós e $1,27 \times 10^3$ s em 32 nós. Em termos relativos, isso corresponde a uma redução do tempo total de aproximadamente 1,5% em 8 nós, 16,8% em 16 nós e 36,7% em 32 nós em relação ao modelo atual.

A figura também evidencia que, na implementação atual, o crescimento do número de nós deixa de produzir ganho de desempenho a partir de 16 nós e passa a ser, na prática, contraproducente em 32 nós — comportamento característico de regime degradado sob *strong scaling*, no qual a contenção do processo escritor mais do que compensa os ganhos de paralelismo computacional. Em contraste, a curva MPI-IO permanece monotonicamente decrescente em todo o intervalo avaliado, indicando que a infraestrutura de armazenamento ainda não atingiu sua capacidade

limite mesmo na maior configuração testada.

Cabe observar que, na implementação MPI-IO, o tempo de E/S torna-se uma fração pequena do tempo total em todas as escalas, permanecendo próximo ou abaixo de 1% a partir de 4 nós. Na implementação atual, por outro lado, a fração de E/S cresce de 7,6% em 8 nós para 28,2% em 16 nós e 49,5% em 32 nós. Na implementação MPI-IO, parte do tempo de simulação passa a ser ocupada pela Coordenação MPI-IO, medida pelas chamadas `MPI_File_Open/MPI_File_Close`: essa parcela cresce de 0,5% em 2 nós para 1,0% em 4 nós, 2,7% em 8 nós, 5,4% em 16 nós e 11,6% em 32 nós. Esse crescimento percentual, contudo, reflete sobretudo a redução do tempo de simulação com o aumento do paralelismo e não um aumento da carga útil tratada por essas chamadas. Como `MPI_File_Open/MPI_File_Close` são executadas uma única vez por execução — no início e no final —, trata-se de um *overhead fixo* em relação à carga útil do problema: não cresce com o número de cenários nem com o número de estágios resolvidos. Esse custo, no entanto, varia com o número de nós computacionais, já que envolve sincronização coletiva entre todos os *ranks* envolvidos na abertura do arquivo compartilhado — e é exatamente esse comportamento que se observa nos dados, com a parcela absoluta crescendo de 42 s em 2 nós para 147 s em 32 nós. Os experimentos aqui apresentados consideram apenas três estágios mensais, o que mantém o tempo total de simulação relativamente curto e infla a fração percentual da Coordenação MPI-IO; em execuções de operação programada típicas do SIN, com horizonte de vários anos e número de cenários muito maior, o custo absoluto dessas chamadas, para uma dada configuração de nós, permanece o mesmo enquanto o tempo total cresce em ordem de magnitude, diluindo a parcela de coordenação para níveis desprezíveis. A partir de 8 nós, e mesmo sob essa inflação relativa do custo de coordenação, a implementação MPI-IO já apresenta tempo total inferior ao da implementação atual.




Figura 4.3: Tempo de execução no Experimento AWS.

A Figura 4.4 apresenta o tempo médio de bloqueio das operações de E/S, em segundos, em função do tamanho dos blocos de dados no Experimento AWS, em escala logarítmica. A comparação mostra que, para blocos de dados muito pequenos, a implementação atual apresenta tempos menores, pois o custo fixo das chamadas MPI-IO se torna dominante em relação ao volume transferido. Esse efeito, contudo, ocorre em uma faixa de tempo baixa, da ordem de microssegundos a poucos milissegundos, e não determina o tempo total da aplicação.

Para blocos de dados médios e grandes, que concentram o impacto de E/S nas maiores escalas, o comportamento se inverte. Em 16 e 32 nós, a implementação atual passa a apresentar tempos de bloqueio elevados nas classes de maior tamanho, chegando à ordem de segundos, enquanto a implementação MPI-IO permanece na ordem de centésimos ou décimos de segundo. Assim, a figura reforça o diagnóstico das Figuras 4.2 e 4.3: a abordagem com escritor único é competitiva apenas em pequena escala ou para blocos de dados muito pequenos, mas perde escalabilidade quando o volume de dados e a concorrência entre processos aumentam.




Figura 4.4: Tempo médio de bloqueio das operações de envio em função do tamanho dos blocos de dados no Experimento AWS (escala logarítmica).

4.1.4 Avaliação do impacto do número de OSTs

Esta subseção tem como objetivo avaliar, no Experimento AWS, o impacto do número de *Object Storage Targets* (OSTs) no desempenho das operações de E/S no sistema de arquivos Lustre. Em ambientes HPC, a quantidade de OSTs está diretamente relacionada ao grau de paralelismo de E/S disponível, uma vez que os dados podem ser distribuídos entre múltiplos dispositivos de armazenamento, permitindo acessos concorrentes por diferentes processos.

A configuração de 10 OSTs aqui considerada é a mesma utilizada no Experimento AWS principal (Subseção 4.1.2, Tabela 4.2); a configuração de 4 OSTs foi obtida em rodada dedicada, com todos os demais parâmetros mantidos constantes — base de dados PMO/PAR de outubro de 2023, 1.536 cenários, três estágios mensais, 24 *ranks* MPI por nó e mesma instrumentação MPI-IO. Os valores absolutos das duas configurações são, portanto, diretamente comparáveis, e o foco da análise é o efeito isolado do número de OSTs sobre o desempenho das operações de E/S.

Para esta avaliação, foram realizados experimentos com a abordagem MPI-IO variando-se a quantidade de OSTs disponíveis no FSx for Lustre, comparando configurações com 4 OSTs e 10 OSTs para execuções com 16 e 32 nós de cálculo. As demais características do experimento foram mantidas constantes, incluindo o volume de dados e o padrão de acesso, de modo a isolar o efeito da infraestrutura de armazenamento.

A Figura 4.5 apresenta o tempo médio de envio por classe de tamanho das mensagens. Cada subfigura corresponde a uma classe de tamanho, enquanto as barras comparam as configurações MPI-IO com 4 e 10 OSTs para 16 e 32 nós de cálculo. Em 16 nós, as classes pequenas apresentam tempos da mesma ordem de grandeza nas duas configurações: 0,014 ms com 4 OSTs contra 0,015 ms com 10 OSTs nas mensagens de até 1 KB, e 0,014 ms contra 0,012 ms nas mensagens de até 128 KB. Nas classes que concentram maior volume de dados, o ganho do paralelismo de armazenamento se manifesta com força: o tempo cai de 82,6 ms para 5,7 ms nas mensagens de até 1 MB (aproximadamente 14,5× mais rápido) e de 524 ms para 47,1 ms nas mensagens de até 50 MB (aproximadamente 11,1×).

O efeito é ainda mais pronunciado em 32 nós, quando a maior concorrência entre processos amplia a diferença entre as duas configurações. As classes pequenas mantêm-se com tempos próximos — 0,018 ms com 4 OSTs contra 0,016 ms com 10 OSTs nas mensagens de até 1 KB, e 0,018 ms contra 0,014 ms nas mensagens de até 128 KB —, mas o ganho nas classes maiores se acentua: o tempo médio cai de 309 ms para 13,8 ms nas mensagens de até 1 MB (cerca de 22,4× mais rápido) e de 1,89 s para 113,5 ms nas mensagens de até 50 MB (cerca de 16,6×). Esses resultados mostram que a redução do número de OSTs aumenta a contenção no acesso aos dados principalmente nas classes de maior volume, sobretudo quando o número de nós de cálculo cresce. Embora a escrita seja realizada em paralelo por meio de MPI-IO, a disponibilidade de menos alvos de armazenamento limita o paralelismo efetivo do Lustre e aumenta o tempo observado nas operações de envio dessas classes.




Figura 4.5: Tempo médio de envio por classe de tamanho das mensagens para configurações MPI-IO com 4 e 10 OSTs.

A Figura 4.6 complementa essa análise ao apresentar a banda agregada média percebida pela aplicação em cada configuração. Com 16 nós, a configuração com 10 OSTs atinge 274,2 Gb/s, contra 49,4 Gb/s com 4 OSTs, ganho de aproximadamente $5,6\times$. Ao passar de 16 para 32 nós, as configurações exibem tendências opostas: com 10 OSTs, a banda cresce para 380,3 Gb/s, enquanto, com 4 OSTs, cai para 16,1 Gb/s. Dessa forma, em 32 nós, o uso de 10 OSTs resulta em ganho de aproximadamente $23,6\times$ sobre a configuração com 4 OSTs. Esse comportamento indica que, quando a concorrência entre processos aumenta, a configuração com menos OSTs passa a limitar a escalabilidade da E/S.

Assim, a análise conjunta das duas figuras indica que o aumento no número de OSTs melhora tanto a largura de banda agregada quanto o tempo médio das operações de envio nas classes de maior volume. A configuração com 10 OSTs permite melhor distribuição das requisições entre os alvos de armazenamento, enquanto a configuração com 4 OSTs concentra o tráfego em menos dispositivos e introduz gargalos mais visíveis no cenário com 32 nós.




Figura 4.6: Banda agregada média percebida pela aplicação na implementação MPI-IO para configurações com 4 e 10 OSTs em 16 e 32 nós.

4.2 Experimento SDumont

O Experimento SDumont corresponde ao supercomputador Santos Dumont (SDumont), adquirido junto à empresa francesa EVIDEN/ATOS/BULL, que está localizado na sede do Laboratório Nacional de Computação Científica (LNCC), em Petrópolis-RJ, atuando como nó central (Tier-0) do Sistema Nacional de Processamento de Alto Desempenho (SINAPAD). Nesse experimento foram utilizados até 32 nós de processamento, cada um equipado com dois processadores Intel Xeon Cascade Lake Gold 6252, totalizando 24 núcleos físicos por nó, com suporte a *hyper-threading*, o que resulta em 48 processadores lógicos disponíveis. Cada nó conta ainda com 384 GB de memória e interconexão de alta velocidade baseada em InfiniBand EDR de 100 Gb/s, projetada para reduzir a latência e aumentar a eficiência em aplicações paralelas de larga escala. Nos experimentos, foi utilizada a biblioteca MPICH2 versão 3.2 e um sistema de arquivos paralelo Lustre v2.12 implementado através do ClusterStor L300 da Cray/HPE. Essa implementação do Lustre é composta por 1 nó MDS (com 1 MDT) e 6 nós OSSs (cada um servindo 1 OST). O *stripe count* foi configurado como 6, com *stripes* de 1 MB, disponibilizando um espaço total de armazenamento de 1,1 PB. Pelos motivos discutidos na introdução do capítulo, também aqui se configurou um *rank* por núcleo físico, totalizando 24 *ranks*

MPI por nó, que processam cenários em paralelo segundo o padrão *bag-of-tasks*.

Diferentemente do FSx for Lustre dedicado utilizado no Experimento AWS, o sistema de arquivos do SDumont é compartilhado com outras cargas de trabalho de HPC executando concorrentemente, o que introduz variabilidade adicional nas medições e amplifica o efeito da contenção sobre os recursos do sistema de arquivos nas maiores escalas. Esse compartilhamento faz do SDumont um cenário mais desafiador para a avaliação da escalabilidade de E/S do que o ambiente isolado da AWS.

4.2.1 Avaliação da implementação atual

Esta subseção analisa o desempenho da arquitetura atual de E/S do SDDP no Experimento SDumont. A Tabela 4.4 sumariza os resultados, considerando 1.536 cenários, três estágios mensais e 24 *ranks* por nó.

O tempo total de execução medido decresce com o aumento do número de nós: 14.703 s em 2 nós, 7.572 s em 4 nós, 4.987 s em 8 nós, 2.993 s em 16 nós e 2.989 s em 32 nós. Essa redução, contudo, perde eficiência rapidamente: o speedup passa de $1,94\times$ em 4 nós para $2,95\times$ em 8 nós, $4,91\times$ em 16 nós e $4,92\times$ em 32 nós, o que corresponde a queda de eficiência de 97,1% para 30,7%. Notavelmente, o tempo total praticamente estagna entre 16 e 32 nós (2.993 s e 2.989 s, respectivamente), sintoma de que o gargalo da arquitetura centralizada já se manifesta a partir de 16 nós e impede ganhos adicionais com o aumento do paralelismo. A banda agregada percebida confirma o diagnóstico: parte de 62,8 Gb/s em 2 nós, recua para 46,2 Gb/s em 4 nós e colapsa a partir de 8 nós, mantendo-se entre 3,8 e 5,4 Gb/s no restante da faixa avaliada. A parcela de E/S, embutida no tempo de simulação, salta de 0,24% em 2 nós para 19,43% em 8 nós, 21,85% em 16 nós e 39,98% em 32 nós, evidência direta de que o gargalo da arquitetura centralizada se intensifica nas maiores escalas.

Tabela 4.4: Desempenho do Experimento SDumont com a implementação atual. O tempo total corresponde ao tempo de execução medido, que inclui computação, E/S e comunicação. A eficiência é calculada em relação à base de 2 nós.

Nós	Banda percebida (Gb/s)	I/O (s)	% I/O	Comunicação (s)	Total (s)	Speedup	Eficiência (%)
2	$62,78 \pm 1,83$	$34,73 \pm 1,01$	0,24%	$374,04 \pm 13,10$	$14\,702,88 \pm 26,41$	1,00×	100,0%
4	$46,19 \pm 3,15$	$75,76 \pm 2,59$	1,00%	$332,55 \pm 12,98$	$7\,571,66 \pm 14,39$	1,94×	97,1%
8	$4,26 \pm 0,29$	$968,97 \pm 6,94$	19,43%	$385,68 \pm 19,75$	$4\,987,34 \pm 77,08$	2,95×	73,7%
16	$5,37 \pm 0,87$	$654,04 \pm 3,73$	21,85%	$395,28 \pm 9,54$	$2\,992,77 \pm 77,20$	4,91×	61,4%
32	$3,77 \pm 1,02$	$1\,194,97 \pm 7,10$	39,98%	$494,93 \pm 15,30$	$2\,988,68 \pm 75,36$	4,92×	30,7%

4.2.2 Avaliação da implementação MPI-IO com escritas independentes

Esta subseção analisa o desempenho da arquitetura proposta no Experimento SDumont, baseada em escritas independentes com MPI-IO sobre o sistema de arquivos Lustre operado pelo ClusterStor L300. A Tabela 4.5 consolida os resultados.

Na implementação MPI-IO, o tempo total decresce ao longo de toda a faixa avaliada: 15.096 s em 2 nós, 7.912 s em 4 nós, 4.151 s em 8 nós, 2.619 s em 16 nós e 2.133 s em 32 nós. Em comparação com a implementação atual, a versão MPI-IO apresenta pequeno sobrecusto em 2 e 4 nós (aumento de 2,7% e 4,5%, respectivamente), mas passa a reduzir o tempo total a partir de 8 nós, com ganhos de 16,8%, 12,5% e 28,6% em 8, 16 e 32 nós. A banda agregada do *layer* de escrita, ao contrário do que ocorre na implementação atual, cresce de forma consistente com o paralelismo: de 5,5 Gb/s em 2 nós para 8,9 Gb/s em 4 nós, 12,1 Gb/s em 8 nós, 18,9 Gb/s em 16 nós e 34,1 Gb/s em 32 nós. O tempo médio de E/S por processo cai de 320 s em 2 nós para 61,6 s em 32 nós, e a parcela percentual de E/S no tempo de simulação permanece abaixo de 5% em todas as configurações.

Tabela 4.5: Desempenho do Experimento SDumont com a implementação MPI-IO. O tempo total corresponde ao tempo de execução medido, que inclui computação, E/S, comunicação e Coordenação MPI-IO. A eficiência é calculada em relação à base de 2 nós.

Nós	Banda percebida (Gb/s)	I/O (s)	% I/O	Comunicação (s)	Coord. (s)	Total (s)	Speedup	Eficiência (%)
2	5,55 ± 0,33	320,27 ± 10,78	2,12%	352,81 ± 7,54	23,24 ± 2,65	15 096,47 ± 40,60	1,00×	100,0%
4	8,89 ± 0,85	270,52 ± 4,45	3,42%	231,00 ± 11,26	32,27 ± 1,40	7 912,23 ± 81,80	1,91×	95,4%
8	12,09 ± 1,33	193,57 ± 2,23	4,66%	222,57 ± 6,92	79,31 ± 19,18	4 151,01 ± 124,19	3,64×	90,9%
16	18,85 ± 1,04	99,41 ± 0,95	3,79%	281,28 ± 16,08	126,49 ± 24,82	2 619,43 ± 88,31	5,76×	72,0%
32	34,10 ± 4,70	61,61 ± 0,78	2,89%	357,72 ± 19,57	230,03 ± 7,78	2 132,82 ± 75,89	7,08×	44,2%

4.2.3 Análise comparativa

Os resultados das duas subseções anteriores são consolidados visualmente nas figuras a seguir, que apresentam, lado a lado, os perfis de banda agregada, tempo de execução e tempo de bloqueio de envio em função do número de nós para as duas implementações no Experimento SDumont.

A Tabela 4.6 resume os principais indicadores comparativos do Experimento SDumont. A coluna de melhoria no tempo total compara diretamente a implementação MPI-IO com a implementação atual para o mesmo número de nós, calculada como $(Total_{atual} - Total_{MPIIO})/Total_{atual}$. Valores positivos indicam redução do tempo total, enquanto valores negativos indicam piora. A MPI-IO apresenta sobre-

custo em pequena escala ($-2,7\%$ em 2 nós e $-4,5\%$ em 4 nós), mas passa a reduzir o tempo total a partir de 8 nós, com ganhos de $16,8\%$, $12,5\%$ e $28,6\%$ em 8, 16 e 32 nós. O ganho de banda também cresce nas maiores escalas: alcança $2,83\times$ em 8 nós, $3,51\times$ em 16 nós e $9,05\times$ em 32 nós. A redução do tempo médio de E/S chega a $80,0\%$ em 8 nós, $84,8\%$ em 16 nós e $94,8\%$ em 32 nós, atestando que a contenção do escritor único é o fator dominante de degradação da implementação atual nessas escalas.

Tabela 4.6: Resumo comparativo entre a implementação atual e MPI-IO no Experimento SDumont. A melhoria no total e a melhoria de I/O são calculadas em relação à implementação atual; valores negativos indicam piora.

Nós	Total atual (s)	Total MPI-IO (s)	Melhoria no total (%)	Banda percebida atual (Gb/s)	Banda percebida MPI-IO (Gb/s)	Ganho de banda perc.	I/O atual (s)	I/O MPI-IO (s)	Melhoria I/O (%)
2	14 702,88	15 096,47	$-2,7\%$	62,78	5,55	$0,09\times$	34,73	320,27	$-822,2\%$
4	7 571,66	7 912,23	$-4,5\%$	46,19	8,89	$0,19\times$	75,76	270,52	$-257,1\%$
8	4 987,34	4 151,01	$16,8\%$	4,26	12,09	$2,83\times$	968,97	193,57	$80,0\%$
16	2 992,77	2 619,43	$12,5\%$	5,37	18,85	$3,51\times$	654,04	99,41	$84,8\%$
32	2 988,68	2 132,82	$28,6\%$	3,77	34,10	$9,05\times$	1 194,97	61,61	$94,8\%$

A Figura 4.7 compara a banda agregada média percebida pela aplicação obtida pela implementação atual e pela implementação MPI-IO. Em 2 e 4 nós, a implementação atual apresenta a maior banda observada, com $62,8\text{ Gb/s}$ e $46,2\text{ Gb/s}$ respectivamente, enquanto a MPI-IO atinge $5,5\text{ Gb/s}$ e $8,9\text{ Gb/s}$ — comportamento esperado em pequena escala, em que o custo fixo da camada MPI-IO ainda não é amortizado pelo paralelismo de escrita. A partir de 8 nós, o quadro se inverte: a banda da implementação atual colapsa para $4,3\text{ Gb/s}$ e a MPI-IO sobe para $12,1\text{ Gb/s}$ — ganho de $2,83\times$. Em 16 nós, a implementação atual permanece nesse patamar baixo, com $5,4\text{ Gb/s}$, enquanto a MPI-IO continua crescendo e alcança $18,9\text{ Gb/s}$ — ganho de $3,51\times$. Em 32 nós, a diferença se acentua: a implementação atual cai para $3,8\text{ Gb/s}$, enquanto a MPI-IO atinge $34,1\text{ Gb/s}$, ganho de $9,05\times$.

Mais relevante que o valor absoluto é o contraste de *comportamento*: a implementação atual exibe queda abrupta entre 4 e 8 nós e permanece em um patamar baixo nas escalas subsequentes (entre $3,8$ e $5,4\text{ Gb/s}$), sintoma da saturação do escritor central sob o Lustre compartilhado do SDumont. A implementação MPI-IO, em contrapartida, apresenta perfil monotonicamente crescente de banda, indicando que a infraestrutura de armazenamento ainda é capaz de absorver maior paralelismo de escrita.




Figura 4.7: Banda agregada média percebida pela aplicação nas implementações atual e MPI-IO no Experimento SDumont.

A Figura 4.8 detalha o tempo médio por processo no Experimento SDumont, separando as parcelas de computação, comunicação, E/S e Coordenação MPI-IO. A parcela Coordenação MPI-IO corresponde às chamadas `MPI_File_Open/MPI_File_Close`, executadas *uma única vez* por execução — na abertura e no fechamento do arquivo de saída. Trata-se, portanto, de um *overhead fixo* em relação à carga útil do problema: não cresce com o número de cenários nem com o número de estágios resolvidos. Esse custo, no entanto, varia com o número de nós computacionais, já que envolve sincronização coletiva entre todos os *ranks* envolvidos na abertura do arquivo compartilhado. As barras de erro indicam somente o desvio padrão do tempo de execução total. Em 2 e 4 nós, a implementação MPI-IO apresenta tempo total levemente superior ao da implementação atual: o custo das operações de coordenação e da própria camada MPI-IO ainda pesa nessas escalas, em que a contenção do escritor único da implementação atual ainda não saturou. A partir de 8 nós, a versão MPI-IO reduz o tempo total em relação à implementação atual, chegando a 28,6% de redução em 32 nós.

Na implementação atual, a parcela de E/S cresce de forma marcante a partir de 8 nós, chegando a representar uma fatia significativa do tempo de simulação. Esse comportamento é compatível com a saturação do processo escritor centralizado no Lustre compartilhado do SDumont. Na implementação MPI-IO, o tempo de E/S é redistribuído entre os processos e permanece reduzido em todas as escalas (abaixo de 5% do tempo de simulação), enquanto o custo da Coordenação MPI-IO passa a compor uma fração visível do tempo total nas maiores configurações — em particular, cresce de cerca de 23 s em 2 nós para 126 s em 16 nós e 230 s em 32 nós.

É importante destacar que a fração relativa da Coordenação MPI-IO observada nestes experimentos é maior do que se espera em execuções reais do SDDP. Como

já discutido, trata-se de um overhead fixo em relação à carga útil do problema — não cresce com o número de cenários nem com o número de estágios resolvidos —, de modo que sua participação no tempo total decresce à medida que a carga computacional aumenta. Nas execuções aqui realizadas, com apenas três estágios mensais e 1 536 cenários, o tempo total de simulação é relativamente baixo, o que infla o peso percentual dessa parcela. Em execuções de operação programada típicas do SIN, com horizonte de vários anos em resolução mensal e número de cenários muito maior, o custo absoluto de coordenação, para uma dada configuração de nós, permanece o mesmo enquanto o tempo total de computação cresce em ordem de magnitude — diluindo a fração relativa da Coordenação MPI-IO para níveis desprezíveis. Assim, a figura evidencia que a abordagem proposta reduz o gargalo centralizado de escrita; o custo residual de coordenação, embora visível na escala dos experimentos, não é uma limitação intrínseca da arquitetura proposta.




Figura 4.8: Decomposição do tempo médio por processo das implementações atual e MPI-IO no Experimento SDumont.

A Figura 4.9 apresenta o tempo médio de bloqueio das operações de envio em função do tamanho dos blocos de dados no Experimento SDumont, em escala logarítmica, organizada em quatro painéis — um por categoria de tamanho.

O painel (a), correspondente a blocos de até 1 KB, mostra tempos de envio

na ordem de poucas dezenas de microssegundos para ambas as implementações em todas as escalas, com diferenças marginais. Para essa granularidade, dominada por chamadas de controle e protocolo, nem o gargalo do escritor único nem o custo fixo da camada MPI-IO se manifestam de forma significativa.

O painel (b), referente a blocos de até 128 KB, evidencia o contraste mais dramático da figura. A implementação atual cresce de $5,7 \times 10^{-5}$ s em 2 nós para $2,7 \times 10^{-3}$ s em 8 nós e $4,1 \times 10^{-3}$ s em 32 nós, enquanto a implementação MPI-IO permanece estável em torno de $1,3 \times 10^{-5}$ s em todas as configurações. Nessa faixa, a contenção do processo escritor da arquitetura atual amplifica-se rapidamente com a concorrência, e a escrita paralela da MPI-IO chega a apresentar vantagem de mais de duas ordens de grandeza em 32 nós.

Os painéis (c) e (d), referentes a blocos de até 1 MB e até 50 MB, mostram um comportamento misto. Em 2 e 4 nós, a implementação atual ainda apresenta tempos menores — 4,6 ms e 21 ms na classe de até 1 MB; 14 ms e 55 ms na classe de até 50 MB —, enquanto a MPI-IO paga seu custo fixo (45 ms, 71 ms, 123 ms e 250 ms, respectivamente). Essa vantagem inicial se inverte a partir de 8 nós: a saturação do escritor único na implementação atual eleva o tempo médio para 0,593 s na classe de até 1 MB e 0,982 s na classe de até 50 MB, contra 0,094 s e 0,433 s da MPI-IO. Em 16 nós, a vantagem da MPI-IO consolida-se: 0,082 s vs. 0,797 s na classe de até 1 MB (uma ordem de grandeza) e 0,586 s vs. 1,36 s na classe de até 50 MB. Em 32 nós, a implementação atual volta a se degradar, chegando a 2,90 s na classe de até 1 MB e 5,16 s na classe de até 50 MB, enquanto a MPI-IO permanece em 0,095 s e 0,791 s, respectivamente.

Em conjunto, os painéis evidenciam um ponto de troca em função da escala: em 2 e 4 nós, a implementação atual é competitiva ou superior em blocos médios e grandes; a partir de 8 nós, a arquitetura MPI-IO se torna sistematicamente vantajosa em todas as classes não triviais, com ganhos de até duas ordens de grandeza nos blocos de até 128 KB. Esse padrão também explica diretamente o colapso da banda agregada da implementação atual mostrado na Figura 4.7: a partir de 8 nós, a maior parte do volume escrito sofre saturação no escritor único.




Figura 4.9: Tempo médio de bloqueio das operações de envio por tamanho de bloco de dados nas implementações atual e MPI-IO no Experimento SDumont (escala logarítmica).

Os resultados apresentados nesta seção demonstram que a adoção da abordagem MPI-IO com escritas independentes endereça o gargalo da arquitetura original associado à concentração das operações de E/S no processo escritor. No SDumont, esse benefício se manifesta a partir de 8 nós: a banda agregada cresce monotonicamente até 34,1 Gb/s em 32 nós, contra um perfil que colapsa e satura na implementação atual; o tempo de E/S é reduzido em 80,0%, 84,8% e 94,8% em 8, 16 e 32 nós, respectivamente. Em 2 e 4 nós, o custo fixo da camada MPI-IO ainda sobrepõe-se ao ganho de paralelismo de escrita, e a implementação atual é ligeiramente mais rápida. A partir de 8 nós, a MPI-IO também reduz o tempo total, com ganho crescente até 28,6% em 32 nós.

A queda de eficiência paralela observada em 32 nós — 30,7% na implementação atual e 44,2% na MPI-IO — e a variabilidade observada refletem, em boa medida, o caráter compartilhado do Lustre do SDumont, em que diferentes cargas de HPC concorrem simultaneamente pelo mesmo sistema de arquivos. Mesmo nesse cenário

hostil, o contraste qualitativo entre o perfil monotonicamente crescente de banda da MPI-IO e o colapso da implementação atual a partir de 8 nós persiste em toda a faixa avaliada, indicando que a vantagem estrutural da escrita paralela se mantém quando a infraestrutura impõe limites significativos.

4.3 Síntese das avaliações

Os dois experimentos — AWS, em ambiente de nuvem com FSx for Lustre dedicado, e SDumont, em supercomputador com Lustre compartilhado entre múltiplas cargas de HPC — convergem para um diagnóstico comum, ainda que com magnitudes diferentes. Em pequena escala (2 e 4 nós), a implementação atual é competitiva ou ligeiramente superior, pois o gargalo do escritor único ainda não saturou e o custo fixo da camada MPI-IO pesa em relação ao tempo total. A partir de 8 nós, o quadro de E/S se inverte: a banda agregada da implementação atual colapsa e satura, refletindo a contenção sobre o adaptador de rede do nó escritor, enquanto a MPI-IO exibe perfil monotonicamente crescente de banda. Esse contraste qualitativo de comportamento — e não apenas o ganho pontual em uma ou outra escala — é o resultado mais robusto deste capítulo.

A magnitude do benefício, no entanto, depende fortemente da infraestrutura de armazenamento subjacente. No FSx for Lustre dedicado da AWS, a abordagem proposta atinge 380,3 Gb/s em 32 nós (ganho de $113\times$ sobre a implementação atual) e reduz o tempo total em até 36,7%, com curva de banda ainda em crescimento. No Lustre compartilhado do SDumont, a banda da MPI-IO chega a 34,1 Gb/s em 32 nós (ganho de $9,1\times$), a redução do tempo de E/S chega a 94,8% e o tempo total cai até 28,6%. Esses ganhos ocorrem em condições adversas de concorrência por metadados e por banda do sistema de arquivos com outras aplicações em execução. A preservação da vantagem estrutural mesmo nesse regime sugere que a arquitetura proposta é portátil entre ambientes heterogêneos, e não dependente das condições idealizadas de uma plataforma dedicada.

A análise do impacto do número de OSTs na AWS reforça que o paralelismo de armazenamento subjacente é parte essencial do ganho: sair de 4 para 10 OSTs amplia a banda agregada em aproximadamente $5,6\times$ em 16 nós e $23,6\times$ em 32 nós, além de reduzir o tempo médio das escritas nas classes de bloco maiores. Essa observação sugere que, em deployments futuros, o dimensionamento da camada de armazenamento — número de OSTs e largura de *stripe* — deve ser tratado como parâmetro de projeto, e não como detalhe operacional.

Esses resultados não esgotam, porém, o estudo da escalabilidade da fase de simulação final do SDDP. A faixa avaliada estendeu-se até 32 nós na AWS e no SDumont; configurações maiores podem revelar comportamentos adicionais, em particular sa-

turação de metadados ou efeitos de coordenação coletiva. O custo da Coordenação MPI-IO, que aqui se mostrou desprezível em valor absoluto mas inflado em participação percentual pelo tamanho reduzido das execuções de teste, merece reavaliação em cargas reais de operação programada do SIN, com horizontes plurianuais. Por fim, o trabalho restringiu-se à fase de simulação final, em que cenários são mutuamente independentes; a aplicabilidade da estratégia à fase de convergência, com seu padrão diferente de comunicação e sincronização, fica como tema natural de continuidade.

Capítulo 5

Trabalhos relacionados

Capítulo 6

Conclusões e trabalhos futuros

Os resultados apresentados nesta dissertação evidenciam que o desempenho da aplicação SDDP é fortemente influenciado pela estratégia adotada para as operações de entrada e saída (E/S). A análise detalhada do comportamento do `MPI_Send` revelou que o tempo de bloqueio associado ao envio de blocos de dados representa um dos principais fatores limitantes da escalabilidade do modelo, sobretudo quando há um único processo responsável pela escrita em disco. Esse gargalo torna-se mais pronunciado à medida que cresce o número de nós computacionais, restringindo a sobreposição entre comunicação e computação e, conseqüentemente, a eficiência paralela da aplicação.

A adoção de uma arquitetura de E/S MPI-IO, baseada em MPI-IO e no sistema de arquivos Lustre, mostrou-se uma alternativa promissora para mitigar esses efeitos. Essa abordagem permite que múltiplos processos MPI realizem operações de escrita de forma paralela e coordenada, eliminando a dependência de um processo escritor único e aproveitando o paralelismo nativo do sistema de arquivos. Além de reduzir o tempo de bloqueio dos processos, essa solução potencializa o uso da largura de banda agregada e melhora a escalabilidade em aplicações com alto volume de dados.

Como trabalhos futuros, propõe-se investigar o impacto de diferentes estratégias de agregação de escrita coletiva (*two-phase I/O*) e o uso de *hints* do ROMIO para otimizar o alinhamento das operações de escrita com a configuração de *striping* do Lustre. Tais aprimoramentos poderão contribuir para a consolidação de um modelo de E/S escalável e portátil, aplicável a uma ampla gama de aplicações científicas e de engenharia com padrões intensivos de acesso a dados.

Referências Bibliográficas

- KANG, Q., LEE, S., HOU, K.-Y., et al. “Improving MPI Collective I/O for High Volume Non-Contiguous Requests With Intra-Node Aggregation”, *IEEE Transactions on Parallel and Distributed Systems*, v. 31, n. 11, pp. 2682–2695, 2020. doi: 10.1109/TPDS.2020.3000458.
- LUU, H., WINSLETT, M., GROPP, W., et al. “A Multiplatform Study of I/O Behavior on Petascale Supercomputers”. In: *Proceedings of the 24th International Symposium on High-Performance Parallel and Distributed Computing*, HPDC '15, pp. 33–44, New York, NY, USA, 2015. Association for Computing Machinery. doi: 10.1145/2749246.2749269.
- XIE, B., ORAL, S., ZIMMER, C., et al. “Characterizing Output Bottlenecks of a Production Supercomputer: Analysis and Implications”, *ACM Transactions on Storage*, v. 15, n. 4, pp. 1–39, 2020. doi: 10.1145/3335205.
- MESSAGE PASSING INTERFACE FORUM. “MPI: A Message-Passing Interface Standard, Version 5.0”. 2025. <https://www.mpi-forum.org/docs/>.
- OPENSFS AND EOFS. *Lustre Software Release 2.x: Operations Manual*, 2025. https://doc.lustre.org/lustre_manual.pdf.
- CONEJO, A. J., CARRIÓN, M., MORALES, J. M. *Decision Making Under Uncertainty in Electricity Markets*, v. 153, *International Series in Operations Research & Management Science*. New York, NY, Springer, 2010. ISBN: 9781441974211. doi: 10.1007/978-1-4419-7421-1.
- ZAKARIA, A., ISMAIL, F. B., LIPU, M. S. H., et al. “Uncertainty Models for Stochastic Optimization in Renewable Energy Applications”, *Renewable Energy*, v. 145, pp. 1543–1571, 2020. doi: 10.1016/j.renene.2019.07.081.
- PEREIRA, M. V. F., PINTO, L. M. V. G. “Multi-stage Stochastic Optimization Applied to Energy Planning”, *Mathematical Programming*, v. 52, n. 1–3, pp. 359–375, 1991.

- MESSAGE PASSING INTERFACE FORUM. “MPI: A Message-Passing Interface Standard, Version 4.1”. 2023. <https://www.mpi-forum.org/>.
- MESSAGE PASSING INTERFACE FORUM. “MPI-2: Extensions to the Message-Passing Interface”. 1997. Specification.
- GROPP, W., LUSK, E., SKJELLUM, A. *Using MPI: Portable Parallel Programming with the Message-Passing Interface*. 2 ed. Cambridge, MA, MIT Press, 1999. ISBN: 9780262571326.
- THAKUR, R., RABENSEIFNER, R., GROPP, W. “Optimization of Collective Communication Operations in MPICH”, *The International Journal of High Performance Computing Applications*, v. 19, n. 1, pp. 49–66, 2005. doi: 10.1177/1094342005051521.
- ROSS, R., THAKUR, R., GROPP, W. *Parallel I/O for High Performance Computing*. Burlington, MA, Morgan Kaufmann, 2010.
- THAKUR, R., GROPP, W., LUSK, E. “Data Sieving and Collective I/O in ROMIO”. In: *Proceedings of the 7th Symposium on the Frontiers of Massively Parallel Computation*, pp. 182–189, 1999a.
- CIRNE, W., BRASILEIRO, F., SAUVÉ, J., et al. “Grid Computing for Bag of Tasks Applications”. In: *Proceedings of the 3rd IFIP Conference on E-Commerce, E-Business and E-Government (I3E)*, 2003.
- BRAAM, P. J. “The Lustre Storage Architecture”, *Cluster File Systems Inc.*, 2002.
- PETRINI, F., KERBYSON, D. J., PAKIN, S. “The Case of the Missing Supercomputer Performance: Achieving Optimal Performance on the 8,192 Processors of ASCI Q”. In: *Proceedings of the 2003 ACM/IEEE Conference on Supercomputing*, p. 55. ACM, 2003. doi: 10.1145/1048935.1050204.
- GRAHAM, R. L., SHIPMAN, G. M., BARRETT, B. W., et al. “Open MPI: A High-Performance, Heterogeneous MPI”. In: *Proceedings of the 5th International Workshop on Algorithms, Models and Tools for Parallel Computing on Heterogeneous Networks*, 2005.
- JACKSON, K. R., RAMAKRISHNAN, L., MURIKI, K., et al. “Performance Analysis of High Performance Computing Applications on the Amazon Web Services Cloud”. In: *Proceedings of the 2010 IEEE Second International Conference on Cloud Computing Technology and Science*, pp. 159–168. IEEE, 2010. doi: 10.1109/CloudCom.2010.69.

- TRAN, A., THEKKEDATH, B. “Running Simcenter STAR-CCM+ on AWS with AWS ParallelCluster, Elastic Fabric Adapter and Amazon FSx for Lustre”. AWS Compute Blog, 2020. Disponível em: <<https://aws.amazon.com/blogs/compute/running-simcenter-star-ccm-on-aws/>>.
- OPERADOR NACIONAL DO SISTEMA ELÉTRICO. “Programa Mensal da Operação — PMO”. <https://www.ons.org.br/>, 2023.
- THAKUR, R., GROPP, W., LUSK, E. “On Implementing MPI-IO Portably and with High Performance”, *Proceedings of the 6th Workshop on I/O in Parallel and Distributed Systems*, pp. 23–32, 1999b.
- CARNS, P., LATHAM, R., ROSS, R., et al. “24/7 Characterization of Petascale I/O Workloads”. In: *Proceedings of the 2009 IEEE International Conference on Cluster Computing and Workshops*, pp. 1–10. IEEE, 2009. doi: 10.1109/CLUSTER.2009.5289150.
- AMDAHL, G. M. “Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities”. In: *Proceedings of the April 18–20, 1967, Spring Joint Computer Conference, AFIPS '67 (Spring)*, pp. 483–485, New York, NY, USA, 1967. Association for Computing Machinery. doi: 10.1145/1465482.1465560.
- INTEL CORPORATION. “Intel Xeon Scalable Processors — 4th Generation (Sapphire Rapids)”. <https://www.intel.com/content/www/us/en/products/details/processors/xeon/scalable.html>, 2023.
- AMAZON WEB SERVICES. “Amazon EC2 C7i Instances — Compute Optimized”. <https://aws.amazon.com/ec2/instance-types/c7i/>, 2024.